

Аннотация

Исследуется проблема прогнозирования распределения тематик в медиапотоке. Показано, что классические регрессионные подходы прогнозирования неустойчивы к появлению нерегулярных циклических изменений с переменным периодом. Предлагается метод ARFilter, который повышает точность регрессионных моделей с помощью выделения подмножества слов словаря, коррелирующих с временным распределением соответствующих тематик. Для отобранных слов строятся локальные прогнозы их нормированных долей, которые затем агрегируются в прогноз распределения тематик. На синтетических данных метод снижает ошибку прогноза в десять раз по сравнению с базовым подходом ARIMA. Разработанный подход не зависит от выбора конкретной авторегрессионной модели и эффективен для прогнозирования высоковолатильных тематических распределений.

Ключевые слова: Временные ряды · Волатильность · Корреляционный фильтр · Медиапоток · Тематическое моделирование · ARIMA · Разложение Дуба.

Содержание

1	Введение	4
2	Постановка задачи прогнозирования тематических рядов	7
3	Построение тематических кластеров	9
4	Модель прогноза будущих частот	12
4.1	Классический авторегрессионный подход	12
4.2	Проблемы и ограничения классического подхода	15
4.3	Альтернативный корреляционный подход	18
5	Модифицированная постановка задачи	23
5.1	Псевдокод алгоритма	24
6	Вычислительный эксперимент	25
6.1	Методы	27
6.2	Описание хода эксперимента	27
6.3	Результаты эксперимента	29
6.3.1	Сводка по построению тематических кластеров	29
6.3.2	Embeddings + К-средних	29
6.3.3	Latent Dirichlet Allocation (LDA) для тем	31
6.3.4	Сводка по прогнозированию будущих частот	32
7	Заключение	35

1 Введение

Способность точно прогнозировать тематические распределения в медиапотоках представляет собой критически важную задачу для современных приложений в маркетинге, медиапроизводстве и исследованиях инноваций. Несмотря на значительный прогресс в методах анализа временных рядов и тематического моделирования, существующие подходы демонстрируют ограниченную эффективность при работе с высоковолатильными текстовыми данными, где присутствие шумовых слов существенно снижает точность прогнозов. Данная работа предлагает метод ARFilter, сочетающий тематическое моделирование с динамической фильтрацией волатильных компонент, что обеспечивает снижение среднеквадратичной ошибки на 91% относительно классических подходов при сохранении интерпретируемости результатов.

Ключевыми для понимания работы являются следующие понятия: медиапоток как хронологическая последовательность документов $\mathcal{D} = \{(d_i, t_i)\}_{i=1}^N$, словарь $\mathcal{W}_{\text{all}}$ — множество n -грамм ($1 \leq n \leq 4$), тематика $T_k \subset \mathcal{W}_{\text{all}}$ — семантический кластер слов, образующий разбиение словаря, и доля темы $\nu_k(t) = \frac{f(T_k, t)}{\sum_j f(T_j, t)}$, где $f(w, t)$ — частота слова в момент времени t . Тематическое моделирование понимается как метод выявления скрытой тематической структуры в текстовых корпусах.

Основная идея метода заключается в комбинации динамического отбора слов по их корреляции с будущим распределением тематик и иерархического прогнозирования нормированных частот отобранных core-слов с последующей агрегацией на уровне тематик. Этот подход основан на фундаментальных принципах причинного анализа Грангера [1], обеспечивающего теоретическую базу для отбора информативных признаков, иерархического прогнозирования [2], демонстрирующего эффективность композитных моделей, и теории разложения стохастических процессов Дуба [3], предоставляющей математический аппарат для разделения детерминированных и стохастических компонент временных рядов [4] [5].

Связь с разложением Дуба: В контексте нашей работы ядро метода ARFilter ($\mathcal{W}_{\text{core}}$) соответствует предсказуемой компоненте в разложении Дуба, характеризующей устойчивые тренды и сезонные паттерны частот

слов. Шумовые компоненты ($\mathcal{W}_{\text{WN}} \cup \mathcal{W}_{\text{SD}}$) аналогичны мартингальной составляющей, описывающей непредсказуемые флуктуации с нулевым математическим ожиданием приращений. Теорема Дуба формализует принцип декомпозиции процесса $X_t = A_t + M_t$, где: - A_t — предсказуемый процесс (аналог $\sum_{w \in \mathcal{W}_{\text{core}}} f(w, t)$) - M_t — мартингал (аналог $\sum_{w \in \mathcal{W}_{\text{noise}}} f(w, t)$) [5]

Развитие этих идей прослеживается в работах по тематическому моделированию [6, 7], обеспечивших переход от анализа отдельных слов к семантическим кластерам, и исследованиях волатильности медиаданных [8], выявивших проблему шумовых слов. Фундаментальный вклад в развитие методов внесли работы по адаптивной фильтрации [9], предложившие новые подходы к обработке сигналов в шумной среде, и исследования динамических тематических моделей [10], расширившие возможности анализа эволюции тем во времени. Параллельно развитие методов анализа временных рядов [11, 12, 13, 14] показало потенциал комплексных подходов, однако их применение к тематическим распределениям оставалось неисследованным, а перенос принципов фильтрации [15] на высокоразмерные текстовые данные требовал адаптации к специфике композиционных рядов. Современные руководства по прогнозированию [16] подчёркивают важность иерархических методов, но не решают проблему шумовых компонент в тематических распределениях.

Современное состояние области характеризуется рядом ограничений. Традиционные методы прогнозирования (ARIMA [17], экспоненциальное сглаживание [15], Prophet [18]) работают с единичными рядами и чувствительны к волатильности медиаданных [8]. Подходы на основе нейронных сетей [19] и вариационных автокодировщиков теряют интерпретируемость и требуют больших объемов данных. Методы кластеризации временных рядов [20] и тематического моделирования [6, 7] решают частичные задачи, но не обеспечивают комплексного прогноза распределений. Моделирование финансовых временных рядов [21] предлагает продвинутое техники для волатильных данных, но не адаптировано к семантическим особенностям медиапотоков. Попытки прогнозирования трендов [22, 23] либо игнорируют тематический контекст, либо используют статическую фильтрацию, неадаптивную к изменению структуры шума, что особенно проблематично

при наличии white-noise и spike-decay слов, вызывающих рост дисперсии и падение автокорреляции тематических рядов ($\rho_k(1) < 0.3$).

Для преодоления этих ограничений предлагается метод ARFilter, вводящий два ключевых механизма: корреляционный фильтр $\theta_w = \mathbb{I}[\text{Corr}(f(w, t), \nu_k(t + 1)) \geq r]$ для динамического отбора слов и иерархическую агрегацию $\hat{\nu}_k(t + 1) = \sum_{w \in T_k} \theta_w g_{\psi_w}(s(w, t))$ для построения прогноза. Преимущества метода включают точность (снижение MSE с 23.0×10^{-3} до 2.0×10^{-3} относительно ARIMA) и совместимость с различными AR-моделями и кластеризаторами (LDA, K-Means). Основное ограничение — необходимость кросс-валидации для выбора порога r — компенсируется теоретическими гарантиями (Теорема Задворнова) и экспериментальной эффективностью.

Научная новизна работы заключается в трех аспектах: новый критерий отбора слов по корреляции с будущим распределением тематик (а не с собственным будущим), теоретическое доказательство снижения MSE при фильтрации волатильных слов, и адаптация аппарата разложения Дуба к задаче фильтрации семантических шумов в композиционных временных рядах. Потенциальное влияние включает приложения в маркетинге для сегментированных аудиторий, социологии для анализа общественных трендов и наукометрии для прогнозирования научных направлений, обеспечивая универсальный инструмент для работы с высоковолатильными распределениями в динамически меняющихся средах.

2 Постановка задачи прогнозирования тематических рядов

Рассмотрим конечное множество тематик $\bar{T} = \{T_1, \dots, T_K\}$ и словарь $\mathcal{W}_{\text{all}}$ из $W = |\mathcal{W}_{\text{all}}|$ слов; каждому кластеру T_k сопоставляется подмножество слов $T_k \subset \mathcal{W}_{\text{all}}$ так, что $T_i \cap T_j = \emptyset$ при $i \neq j$ и $\bigcup_{k=1}^K T_k = \mathcal{W}_{\text{all}}$. Для каждого слова $w \in \mathcal{W}_{\text{all}}$ и момента времени $t \in \{0, \dots, T-1\}$ задана частота $f(w, t) \in \mathbb{N}_{\geq 0}$, определяющая число вхождений слова w в тематическом потоке текстов; агрегированная частота темы T_k равна

$$f(T_k, t) = \sum_{w \in T_k} f(w, t),$$

а распределение тематик во времени задаётся

$$\nu_k(t) = \frac{\sum_{w \in T_k} f(w, t)}{\sum_{j=1}^K \sum_{w \in T_j} f(w, t)}, \quad \bar{\nu}(t) = (\nu_1(t), \dots, \nu_K(t)), \quad \sum_{k=1}^K \nu_k(t) = 1.$$

Предполагается существование оценки $\hat{\bar{\nu}}: \mathbb{N}^{W \times T} \rightarrow \mathbb{R}^K$, удовлетворяющей

$$\hat{\bar{\nu}}(t) = \hat{\bar{\nu}}(t \mid \bar{\varphi}, t-1, \dots, t-t_0), \quad \sum_{k=1}^K \hat{\nu}_k(t) = 1, \quad \mathbb{E}[\|\bar{\nu}(t) - \hat{\bar{\nu}}(t)\|_2^2] \rightarrow \min_{\bar{\varphi}}.$$

Данные обладают следующими свойствами: (i) $f(w, t) \in \mathbb{N}_{\geq 0}$ для всех w и t ; (ii) формула для $\nu_k(t)$ задаёт корректную нормировку $\sum_k \nu_k(t) = 1$; (iii) при малых $f(w, t) \ll 1$ дисперсия $\text{Var}[f(w, t)]$ может быть существенной. В качестве модели выступает прогноз распределения тематик на момент t по предыстории длиной t_0

$$\hat{\bar{\nu}}(t \mid \bar{\varphi}, t-1:t-t_0), \quad \bar{\varphi} \in \mathbb{R}^d,$$

а его качество измеряется среднеквадратичной ошибкой

$$\mathcal{L}(\bar{\varphi}) = \sum_t \|\bar{\nu}(t) - \hat{\bar{\nu}}(t \mid \bar{\varphi})\|_2^2$$

с последующей минимизацией

$$\min_{\bar{\varphi} \in \mathbb{R}^d} \sum_t \left\| \bar{\nu}(t) - \widehat{\bar{\nu}}(t \mid \bar{\varphi}, t-1:t-t_0) \right\|_2^2.$$

Для проверки обобщающей способности используется стратегия скользящего окна: интервал $\{0, \dots, T-1\}$ разбивается на обучающий и тестовый сегменты длинами T_{train} и T_{test} , причём на каждом шаге модель обучается на отрезке $[t-t_0, t-1]$ и проверяется в точке t . Итоговая цель — построить устойчивую модель, способную надёжно прогнозировать распределение тематических частот в присутствии аномалий и циклических колебаний.

3 Построение тематических кластеров

Пусть $\mathcal{W}_{\text{all}} = \{w_1, \dots, w_W\}$ — словарь n -грамм ($1 \leq n \leq 4$). Требуется построить разбиение $\bar{T} = \{T_1, \dots, T_K\}$ такое, что $T_i \cap T_j = \emptyset$ и $\bigcup_{k=1}^K T_k = \mathcal{W}_{\text{all}}$.

Метод 1 (Embeddings+ k -means). Определяется отображение $E: \mathcal{W}_{\text{all}} \rightarrow \mathbb{R}^d$, $E(w) = \mathbf{e}_w$, получающее контекстуальные встраивания слов при помощи модели all-MiniLM-L12-v2 из библиотеки Sentence Transformers [24, 25]. Для фиксированного числа кластеров K' решается задача

$$\min_{\{T_k\}_{k=1}^{K'}} \sum_{k=1}^{K'} \sum_{w \in T_k} \|\mathbf{e}_w - \boldsymbol{\mu}_k\|_2^2, \quad \boldsymbol{\mu}_k = \frac{1}{|T_k|} \sum_{w \in T_k} \mathbf{e}_w,$$

то есть применяется алгоритм k -средних к полученной матрице встраиваний; подробности алгоритма приводятся в [7], поэтому здесь они опущены. В результате каждое слово $w \in \mathcal{W}_{\text{all}}$ однозначно попадает в один из кластеров T_k , удовлетворяя исходным условиям разбиения.

Метод 2 (Latent Dirichlet Allocation). Второй алгоритм работает следующим образом. Этапы предварительной обработки включают лемматизацию, удаление стоп-слов и отбор слов длиной от двух до трёх символов, после чего обучается модель латентного размещения Дирихле (Latent Dirichlet Allocation, LDA) [6]. LDA представляет собой вероятностную модель тем, выявляющую скрытые (латентные) темы в корпусе документов; она исходит из предположения, что каждый документ является смесью нескольких тем, а каждое слово принадлежит одной из этих тем.

Алгоритм LDA формулируется так: сначала для каждой темы $k \in \{1, \dots, K'\}$ выбирается распределение слов $\varphi_k \sim \text{Dirichlet}(\beta)$, где β служит гиперпараметром априорного распределения Дирихле; далее для каждого документа $d \in \{1, \dots, D\}$ выбирается распределение тем $\theta_d \sim \text{Dirichlet}(\alpha)$ с гиперпараметром α , после чего для каждого слова w_{dn} внутри документа d последовательно выбираются тема $z_{dn} \sim \text{Multinomial}(\theta_d)$ и само слово $w_{dn} \sim \text{Multinomial}(\varphi_{z_{dn}})$. Совместное распределение всех переменных модели — распределений тем θ , распределений слов φ , назначенных тем $\mathbf{z}$ и

наблюдаемых слов $\mathbf{w}$ — записывается следующим образом:

$$p(\theta, \varphi, \mathbf{z}, \mathbf{w} \mid \alpha, \beta) = \prod_{k=1}^{K'} p(\varphi_k \mid \beta) \prod_{d=1}^D p(\theta_d \mid \alpha) \prod_{n=1}^{N_d} p(z_{dn} \mid \theta_d) p(w_{dn} \mid \varphi_{z_{dn}}) \quad (1)$$

Задача вывода в модели LDA заключается в вычислении апостериорного распределения скрытых переменных θ , φ и $\mathbf{z}$ по наблюдаемым словам $\mathbf{w}$ при заданных гиперпараметрах α и β ; из-за вычислительной сложности точный вывод заменяется приближёнными техниками (например, вариационным выводом или коллапсированным сэмплированием Гиббса). Кластеризация затем осуществляется правилом $w \mapsto T_{\arg \max_k \theta_{w,k}}$.

Оптимальное значение K определяется по метрике средней когерентности C_{cv} [26], измеряющей семантическое сходство слов внутри кластера и, следовательно, его интерпретируемость; выбирается такое K , которое минимизирует

$$K = \arg \min_{K' \in \mathbb{N}} \frac{1}{K'} \sum_{m=0}^{K'-1} C_{cv}(c_m).$$

Мера когерентности C_{cv} вычисляется как

$$C_{cv} = \frac{1}{|S_{\text{set}}^{\text{one}}|} \sum_{(W_0, W_*) \in S_{\text{set}}^{\text{one}}} \tilde{m}_{\cos(\text{nlr}, 1)}(W_0, W_*),$$

где $S_{\text{set}}^{\text{one}} = \{(W_0, W_*) \mid W_0 = \{w_i\}, w_i \in W, W_* = W\}$ — сегментация, задающая множество пар подмножеств слов, а $\tilde{m}_{\cos(\text{nlr}, 1)}(W_0, W_*)$ — косинусное сходство между контекстными векторами W_0 и W_* , измеряющее, насколько хорошо W_* «объясняет» W_0 .

Выбор метода. Цель данного этапа состоит в сравнении описанных методов по качеству кластеризации и выборе одного из них для дальнейшего использования в задаче прогнозирования; для этого введён критерий, основанный на когерентности: пусть $(C_{cv}^{\text{Emb}}, C_{cv}^{\text{LDA}})$ обозначает значения когерентности при оптимальном числе кластеров K^* , тогда

$$\text{Модель} = \begin{cases} \text{Embeddings} + k\text{-means}, & |C_{cv}^{\text{Emb}} - C_{cv}^{\text{LDA}}| < 0.1 \text{ и } C_{cv}^{\text{Emb}} > 0.5, \\ \text{LDA}, & \text{иначе,} \end{cases}$$

что допускает небольшое снижение метрики у k -means по сравнению с LDA, поскольку первый подход проще и выигрывает по ряду иных характеристик; далее, для каждого момента времени $t \in \{0, \dots, T - 1\}$ и каждой темы $T_k \in \bar{T}$ определяются агрегированные частоты $f(T_k, t) = \sum_{w \in T_k} f(w, t)$ и относительные значения

$$\nu_k(t) = \frac{f(T_k, t)}{\sum_{j=1}^K f(T_j, t)},$$

в результате чего формируются ряды $\{f(T_k, t)\}_t$, служащие исходными данными для последующих прогнозных моделей.

4 Модель прогноза будущих частот

4.1 Классический авторегрессионный подход

Классический метод основывается на авторегрессионной модели, прогнозирующей частоты тематик по их прошлым значениям; обычно применяются модели семейства ARIMA, например реализация Prophet. Для каждой темы $T_k \in \bar{T}$ вводится скалярный ряд $y_k(t) = \nu_k(t)$, $t \in \{0, \dots, T-1\}$, где $\nu_k(t)$ определена в (3).

Пусть B — оператор сдвига, $B^j y_k(t) = y_k(t-j)$. Сезонная авторегрессионная интегрированная скользящая средняя $SARIMA(p,d,q)(P,D,Q)_m$, являющаяся расширением ARIMA с учётом сезонности, описывается уравнением

$$(1 - \varphi_1 B)(1 - \Phi_1 B^m)(1 - B)^d(1 - B^m)^D y_t = (1 + \theta_1 B)(1 + \Theta_1 B^m) \varepsilon_t,$$

где p - порядок несезонной авторегрессии, d - порядок несезонного дифференцирования, q - порядок несезонного скользящего среднего, P - порядок сезонной авторегрессии, D - порядок сезонного дифференцирования, Q - порядок сезонного скользящего среднего, m - количество периодов в сезонном цикле, φ_1 - параметр несезонной авторегрессии, Φ_1 - параметр сезонной авторегрессии, θ_1 - параметр несезонного скользящего среднего, Θ_1 - параметр сезонного скользящего среднего, B - оператор сдвига назад ($B^j y_t = y_{t-j}$), а ε_t - белый шум.

Алгоритм SARIMA реализуется последовательно: сперва выполняется идентификация, то есть выбор порядков p , d , q , P , D , Q и длины сезонного цикла m на основе графиков автокорреляционной (ACF) и частичной автокорреляционной (PACF) функций и тестов на стационарность; затем происходит оценка параметров φ_1 , Φ_1 , θ_1 , Θ_1 и дисперсии шума σ^2 , обычно методом максимального правдоподобия или условных наименьших квадратов; после этого проводится диагностика адекватности модели через анализ остатков на автокорреляцию, нормальность распределения и гомоскедастичность; и, наконец, формируются точечные и интервальные прогнозы

по рекуррентной схеме

$$\hat{y}_{t+h|t} = \varphi_1 \hat{y}_{t+h-1|t} + \Phi_1 \hat{y}_{t+h-m|t} - \theta_1 \hat{\varepsilon}_{t+h-1|t} - \Theta_1 \hat{\varepsilon}_{t+h-m|t}, \quad \hat{\varepsilon}_{t+h|t} = 0 \text{ при } h > 0,$$

где $\hat{y}_{t+h|t}$ — прогноз на горизонт h шагов вперёд, полученный на основе оценённой модели.

Точечный прогноз определяется как

$$\hat{y}_k(t+1) = \mathbb{E}_{\hat{\psi}_k} [y_k(t+1) \mid \mathcal{F}_t],$$

а для обеспечения нормировки $\sum_{k=1}^K \hat{\nu}_k(t+1) = 1$ применяется преобразование

$$\hat{\nu}_k(t+1) = \frac{\hat{y}_k(t+1)}{\sum_{j=1}^K \hat{y}_j(t+1)},$$

при этом качество прогноза оценивается метриками MAE и MSE, что эквивалентно функционалу

$$\mathcal{L} = \sum_t \|\bar{\nu}(t) - \hat{\bar{\nu}}(t)\|_2^2.$$

Подбор (p_k, d_k, q_k) и вычисление $\hat{y}_k(t+1)$ выполнялись с помощью библиотеки Prophet [27], представляющей временной ряд в виде аддитивной регрессии

$$y(t) = g(t) + s(t) + h(t) + \varepsilon_t,$$

где $g(t)$ отвечает за тренд, $s(t)$ за сезонность, $h(t)$ за праздничные эффекты, а ε_t моделирует случайную ошибку. Тренд $g(t)$ может задаваться кусочно-линейной зависимостью

$$g_{\text{lin}}(t) = (k + \sum_{j=1}^S \delta_j)t + (m + \sum_{j=1}^S \gamma_j)$$

или логистическим ростом

$$g_{\text{log}}(t) = \frac{C(t)}{1 + \exp(-g_{\text{lin}}(t))},$$

что позволяет гибко описывать как линейные, так и насыщаемые динамики.

Сезонная компонента описывается рядом Фурье

$$s(t) = \sum_{n=1}^N (a_n \cos(2\pi nt/P) + b_n \sin(2\pi nt/P)),$$

праздничные эффекты моделируются суммой индикаторных функций

$$h(t) = \sum_{i=1}^L \theta_i \mathbb{I}_{t \in D_i},$$

а параметры модели оцениваются максимизацией правдоподобия, что эквивалентно решению $\hat{\theta} = \arg \min_{\theta} \left[-\log p(y \mid \theta) \right] = \arg \min_{\theta} \left\{ \frac{n}{2} \log(2\pi) + \frac{n}{2} \log(\sigma^2) + \frac{1}{2\sigma^2} \sum_t (y(t) - \sum_i f_i(t))^2 \right\}$, где θ — вектор параметров, n — число наблюдений, σ^2 — дисперсия ошибки, $y(t)$ — фактические значения ряда, а $f_i(t)$ — отдельные компоненты модели.

Прогноз формируется экстраполяцией оценённого тренда, добавлением сезонной составляющей и учётом праздничных эффектов, что даёт

$$\hat{y}(t+h) = \hat{g}(t+h) + \hat{s}(t+h) + \hat{h}(t+h).$$

4.2 Проблемы и ограничения классического подхода

Основная проблема классического подхода заключается в том, что он усредняет все слова с равными весами, не учитывая их различную предсказательную способность относительно будущего распределения тематик. Анализ временных рядов частот слов показывает, что слова в словаре могут иметь принципиально разную временную структуру и, следовательно, разный вклад в точность прогноза. Поэтому на основании корреляционных свойств и характера временной эволюции словарь целесообразно разложить на три непересекающиеся части

$$\mathcal{W}_{\text{all}} = \mathcal{W}_{\text{core}} \cup \mathcal{W}_{\text{WN}} \cup \mathcal{W}_{\text{SD}}, \quad \mathcal{W}_a \cap \mathcal{W}_b = \emptyset, a \neq b,$$

при этом ядро $\mathcal{W}_{\text{core}}$ составляют слова с устойчивой сезонно-трендовой структурой и высокой корреляцией с будущими значениями соответствующих тематик,

$$\mathcal{W}_{\text{core}} = \{w \in \mathcal{W}_{\text{all}} \mid \rho_w := \text{Corr}(f(w, t), f(T_k, t + 1)) \geq r, w \in T_k\},$$

а именно эти слова обладают наибольшей предсказательной ценностью и формируют основу устойчивой динамики тематических рядов.

Вторую группу образуют white-noise слова $\mathcal{W}_{\text{WN}}$, то есть мультитематические слова, которые часто переходят между темами и потому моделируются случайной ошибкой без предсказательной силы; их частоты описываются

$$\mathcal{W}_{\text{WN}} = \{w \in \mathcal{W}_{\text{all}} \mid f(w, t) = [\varepsilon_w(t)]_+, \rho_w = 0\}$$

где $\varepsilon_w(t) \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(\mu_{\text{WN}}, \sigma_{\text{WN}}^2)$, $[x]_+ = \max\{0, x\}$. Так что их вклад в $\nu_k(t)$ представляет собой чистый шум и лишь повышает дисперсию прогноза.

Третью группу составляют spike-decay слова $\mathcal{W}_{\text{SD}}$ - слова с нерегулярными всплесками активности и переменным периодом. Хотя они и сохраняют стационарность ряда, но значительно увеличивают дисперсию ошибки прогноза:

$$\mathcal{W}_{\text{SD}} = \{w \in \mathcal{W}_{\text{all}} \mid f(w, t) = [S_w(t) + \varepsilon_w(t)]_+, \quad \rho_w(\tau) \approx 0\}$$

где $S_w(t) = \sum A_{w,m} \mathcal{K}(t - \tau_{w,m})$, $\mathcal{K}(\tau) = \frac{e^{-\lambda|\tau|}}{1+\tau^2}$ и $\varepsilon_w(t) \sim \mathcal{N}(\mu_{SD}, \sigma_{SD}^2)$. Сигнал $S_w(t)$ порождает редкие пики с экспоненциальным затуханием; поскольку $\text{Var } f(w, t) \gg \text{Var } f(u, t)$ для $u \in \mathcal{W}_{\text{core}}$, включение таких слов без учёта их особенностей существенно ухудшает качество прогноза.

Воздействие на агрегаты. Для темы T_k представим $f(T_k, t) = f^{(\text{core})}(T_k, t) + f^{(\text{WN})}(T_k, t) + f^{(\text{SD})}(T_k, t)$, где компоненты соответствуют разбиению слов $\mathcal{W}_{\text{all}} = \mathcal{W}_{\text{core}} \cup \mathcal{W}_{\text{WN}} \cup \mathcal{W}_{\text{SD}}$. Введём обозначения: $\sigma_{\text{WN}}^2 := \text{Var}(f^{(\text{WN})}(T_k, t))$, $\sigma_{\text{SD}}^2 := \text{Var}(f^{(\text{SD})}(T_k, t))$.

Утверждение 1 (Задворнов, 2025) Пусть $\mathcal{W}_{\text{all}} = \mathcal{W}_{\text{core}} \cup \mathcal{W}_{\text{WN}} \cup \mathcal{W}_{\text{SD}}$, $\mathcal{W}_a \cap \mathcal{W}_b = \emptyset$ при условии попарной некоррелированности компонент

$$\forall a \neq b, \forall \tau \in \mathbb{Z}: \quad \text{Cov}(f^{(a)}(T_k, t), f^{(b)}(T_k, t + \tau)) = 0$$

Тогда

$$\text{Cov}(f(T_k, t), f(T_k, t + 1)) = \text{Cov}(f^{(\text{core})}(t), f^{(\text{core})}(t + 1))$$

и

$$\rho_k(1) = \frac{\text{Cov}^{\text{core}}}{\text{Var}^{\text{core}} + \sigma_{\text{WN}}^2 + \sigma_{\text{SD}}^2}.$$

Доказательство. Доказательство п.1: Распишем ковариацию, используя линейность и условие некоррелированности:

$$\begin{aligned} & \text{Cov}(f(T_k, t), f(T_k, t + 1)) \\ &= \sum_{a,b} \text{Cov}(f^{(a)}(t), f^{(b)}(t + 1)) \\ &= \sum_a \text{Cov}(f^{(a)}(t), f^{(a)}(t + 1)) \quad (\text{при } a \neq b \text{ ковариации нулевые}). \end{aligned}$$

Для $\mathcal{W}_{\text{WN}}$ по определению $\rho_w = 0$, откуда $\text{Cov}(f^{(\text{WN})}(t), f^{(\text{WN})}(t + 1)) = 0$. Для $\mathcal{W}_{\text{SD}}$ по условию $\rho_w(\tau) \approx 0$ при $\tau \neq 0$, следовательно, $\text{Cov}(f^{(\text{SD})}(t), f^{(\text{SD})}(t + 1)) \approx 0$.

Таким образом:

$$\text{Cov}(f(T_k, t), f(T_k, t + 1)) = \text{Cov}(f^{(\text{core})}(t), f^{(\text{core})}(t + 1)).$$

Доказательство п.2: Дисперсия суммы:

$$\begin{aligned}
 \text{Var } f(T_k, t) &= \text{Var} \left(\sum_a f^{(a)}(t) \right) \\
 &= \sum_a \text{Var}(f^{(a)}(t)) \quad (\text{ковариации между компонентами нулевые}) \\
 &= \text{Var } f^{(\text{core})}(t) + \sigma_{\text{WN}}^2 + \sigma_{\text{SD}}^2.
 \end{aligned}$$

Лаг-1 автокорреляция:

$$\rho_k(1) = \frac{\text{Cov}(f(t), f(t+1))}{\text{Var } f(t)} = \frac{\text{Cov}^{(\text{core})}}{\text{Var } f^{(\text{core})}(t) + \sigma_{\text{WN}}^2 + \sigma_{\text{SD}}^2}.$$

□

Из утверждения 1 непосредственно следует:

$$\rho_k(1) = \frac{\text{Cov}(f^{(\text{core})}(T_k, t), f^{(\text{core})}(T_k, t+1))}{\text{Var } f(T_k, t)} \leq \rho_k^{\text{core}} \frac{\text{Var } f^{(\text{core})}(T_k, t)}{\text{Var } f^{(\text{core})}(T_k, t) + \sigma_{\text{WN}}^2 + \sigma_{\text{SD}}^2},$$

где ρ_k^{core} – лаг-1 автокорреляция ядра.

Вывод для ARIMA-прогноза: чем больше σ_{WN}^2 и σ_{SD}^2 , тем сильнее снижается $\rho_k(1)$, нарушая предпосылку AR-модели о существенной корреляционной зависимости, и тем сильнее размывается сигнал, что приводит к деградации AR-прогноза. Отсюда необходимость альтернативного подхода, который учётывает $\mathcal{W}_{\text{WN}} \cup \mathcal{W}_{\text{SD}}$ в прогностической модели.

4.3 Альтернативный корреляционный подход

Альтернативный подход заключается в рассмотрении вектора корреляций частот слов с будущими значениями их тематик (корреляционный метод) и выделении для прогноза тематики только слов с наибольшими корреляционными значениями. Далее для каждого слова w_k построить отдельную AR-модель, предсказывающую популярность (относительную долю) слова w_k среди core-слов $\mathcal{W}_{\text{core}}$ в момент t . Относительная доля считается как количество упоминаний слова за период, поделённое на количество упоминаний выделенных слов за период. Далее суммировать и нормировать прогнозы слов, чтобы в итоге получить популярность тематики как сумму популярностей слов внутри неё.

В рамках корреляционного скрининга для каждого $w \in \mathcal{W}_{\text{all}}$ оценивается корреляция с будущим значением соответствующей тематики

$$\hat{\rho}_w := \text{Corr}(f(w, t), f(T_k, t + 1)), \quad t \in T_{\text{train}}, w \in T_k,$$

после чего вводится индикатор

$$\theta_w = \mathbb{I}[\hat{\rho}_w \geq r], \quad r \in (0, 1), \quad \bar{\theta} \in \{0, 1\}^W, \quad \mathcal{W}_{\text{core}} = \{w : \theta_w = 1\},$$

и для $t \in \{0, \dots, T - 1\}$ формируются нормированные ряды

$$s(w, t) = \frac{f(w, t)}{\sum_{v \in \mathcal{W}_{\text{core}}} f(v, t)}, \quad w \in \mathcal{W}_{\text{core}}.$$

Для каждого core-слова $w \in \mathcal{W}_{\text{core}}$ формируется авторегрессионный прогноз $\hat{s}(w, t + 1 | \psi_w) = g_{\psi_w}(s(w, t), \dots, s(w, t - t_0 + 1))$, где вектор параметров $\psi_w \in \mathbb{R}^{d_w}$ оценивается на обучающем интервале методом наименьших квадратов; далее все полученные значения переводятся в вероятностную шкалу по правилу

$$\tilde{s}(w, t + 1) = \frac{\hat{s}(w, t + 1 | \psi_w)}{\sum_{v \in \mathcal{W}_{\text{core}}} \hat{s}(v, t + 1 | \psi_v)}, \quad \sum_{w \in \mathcal{W}_{\text{core}}} \tilde{s}(w, t + 1) = 1,$$

после чего относительная частота темы T_k в момент $t + 1$ вычисляется агрегированием нормированных прогнозов

$$\hat{\nu}_k(t + 1) = \sum_{w \in T_k} \theta_w \tilde{s}(w, t + 1), \quad \sum_{k=1}^K \hat{\nu}_k(t + 1) = 1,$$

Таким образом $\mathcal{W}_{\text{WN}} \cup \mathcal{W}_{\text{SD}}$ автоматически исключаются при $\hat{\rho}_w < r$, а прогноз строится только на информативном подмножестве $\mathcal{W}_{\text{core}}$.

Теорема о снижении MSE при фильтрации слов (Задворнов, 2025) Пусть для тематики T_k :

1. $\mu_k = \mathbb{E}[\nu_k(t) \mid \mathcal{F}_{t-1}]$ - условное матожидание распределения по всем словам
2. $\mu_k^{(\text{core})} = \mathbb{E}[\hat{\nu}_k^{(\text{core})}(t) \mid \mathcal{F}_{t-1}]$ - условное матожидание по core-словам
3. Выполнены условия Утверждения 1 о разбиении словаря

и дополнительно выполнены условия на шумовые слова:

1. Для $w \in \mathcal{W}_{\text{WN}}$: $\mathbb{E}[f(w, t) \mid \mathcal{F}_{t-1}] \leq C_{\text{WN}} \sigma_{\text{WN}}$
2. Для $w \in \mathcal{W}_{\text{SD}}$: $\mathbb{E}[f(w, t) \mid \mathcal{F}_{t-1}] \leq C_{\text{SD}} \sigma_{\text{SD}}$ (в отсутствие пиков)
3. $|\mathcal{W}_{\text{WN}}| C_{\text{WN}}^2 + |\mathcal{W}_{\text{SD}}| C_{\text{SD}}^2 < \varkappa$

где $\varkappa > 0$ - минимальное собственное значение информационной матрицы модели прогноза.

Тогда:

$$\mathbb{E}[\mathcal{L}_{\text{ARFilter}} \mid \mathcal{F}_t] := \text{MSE}(\hat{\nu}_k^{(\text{core})}(t)) < \text{MSE}(\hat{\nu}_k^{(\text{all})}(t)) =: \mathbb{E}[\mathcal{L}_{\text{baseline}} \mid \mathcal{F}_t]$$

Доказательство. Шаг 1: Ошибки прогнозов

$$\nu_k(T - 1) = \mu_k + \varepsilon_k, \quad \mathbb{E}[\varepsilon_k \mid \mathcal{F}_{T-2}] = 0, \quad \text{Var}(\varepsilon_k \mid \mathcal{F}_{T-2}) = \sigma_k^2.$$

Из условия несмещенности для полного прогноза: $\mathbb{E}[\hat{\nu}_k^{(\text{all})}(T - 1) \mid \mathcal{F}_{T-2}] = \mu_k$

Для прогноза по стабильным словам:

$$\mathbb{E}[\hat{\nu}_k^{(\text{core})}(T-1) \mid \mathcal{F}_{T-2}] = \mu_k^{(\text{core})} = \sum_{w \in \mathcal{W}_{\text{core}} \cap T_k} \mathbb{E}[X_w(T-1) \mid \mathcal{F}_{T-2}]$$

Заметим, что в общем случае $\mu_k^{(\text{core})} \neq \mu_k$, но нам это не важно для дисперсии. Ошибки прогнозов:

$$e^{(\text{all})} = \nu_k(T-1) - \hat{\nu}_k^{(\text{all})}(T-1) = \varepsilon_k + (\mu_k - \hat{\nu}_k^{(\text{all})}(T-1))$$

$$e^{(\text{core})} = \nu_k(T-1) - \hat{\nu}_k^{(\text{core})}(T-1) = \varepsilon_k + (\mu_k - \hat{\nu}_k^{(\text{core})}(T-1))$$

Тогда условное MSE: $\mathbb{E}[(e^{(\text{all})})^2 \mid \mathcal{F}_{T-2}] = \mathbb{E}[\varepsilon_k^2 \mid \mathcal{F}_{T-2}] + \mathbb{E}[(\mu_k - \hat{\nu}_k^{(\text{all})}(T-1))^2 \mid \mathcal{F}_{T-2}] + 2\mathbb{E}[\varepsilon_k(\mu_k - \hat{\nu}_k^{(\text{all})}(T-1)) \mid \mathcal{F}_{T-2}] = \sigma_k^2 + \text{Var}(\hat{\nu}_k^{(\text{all})}(T-1) \mid \mathcal{F}_{T-2})$
Поскольку ε_k не зависит от $\hat{\nu}_k^{(\text{all})}(T-1)$ (который строится по истории до T-2) и $\mathbb{E}[\varepsilon_k \mid \mathcal{F}_{T-2}] = 0$, то ковариационное слагаемое равно 0. Аналогично:

$$\mathbb{E}[(e^{(\text{core})})^2 \mid \mathcal{F}_{T-2}] = \sigma_k^2 + \text{Var}(\hat{\nu}_k^{(\text{core})}(T-1) \mid \mathcal{F}_{T-2}) + (\mu_k - \mu_k^{(\text{core})})^2$$

Потому что:

$$e^{(\text{core})} = \varepsilon_k + (\mu_k - \hat{\nu}_k^{(\text{core})}(T-1)) = \varepsilon_k + (\mu_k - \mu_k^{(\text{core})}) + (\mu_k^{(\text{core})} - \hat{\nu}_k^{(\text{core})}(T-1))$$

Тогда:

$$\begin{aligned} \mathbb{E}[(e^{(\text{core})})^2 \mid \mathcal{F}_{T-2}] &= \mathbb{E}[\varepsilon_k^2] + (\mu_k - \mu_k^{(\text{core})})^2 + \mathbb{E}[(\mu_k^{(\text{core})} - \hat{\nu}_k^{(\text{core})}(T-1))^2] \\ &+ 2\mathbb{E}[\varepsilon_k(\mu_k - \mu_k^{(\text{core})})] + 2\mathbb{E}[\varepsilon_k(\mu_k^{(\text{core})} - \hat{\nu}_k^{(\text{core})}(T-1))] + 2(\mu_k - \mu_k^{(\text{core})})\mathbb{E}[\mu_k^{(\text{core})} - \hat{\nu}_k^{(\text{core})}(T-1)] \end{aligned}$$

$$\text{Заметим: } \mathbb{E}[\varepsilon_k(\mu_k - \mu_k^{(\text{core})}) \mid \mathcal{F}_{T-2}] = (\mu_k - \mu_k^{(\text{core})})\mathbb{E}[\varepsilon_k \mid \mathcal{F}_{T-2}] = 0$$

$$\mathbb{E}[\varepsilon_k(\mu_k^{(\text{core})} - \hat{\nu}_k^{(\text{core})}(T-1)) \mid \mathcal{F}_{T-2}] = \mathbb{E}[\varepsilon_k \mid \mathcal{F}_{T-2}] \cdot (\mu_k^{(\text{core})} - \mathbb{E}[\hat{\nu}_k^{(\text{core})}(T-1) \mid \mathcal{F}_{T-2}]) = 0$$

$$\mathbb{E}[\mu_k^{(\text{core})} - \hat{\nu}_k^{(\text{core})}(T-1) \mid \mathcal{F}_{T-2}] = 0 \text{ (по условиям из утверждения 1, примененному к каждому слову и агрегированию)}$$

Поэтому: $\mathbb{E}[(e^{(\text{core})})^2 \mid \mathcal{F}_{T-2}] = \sigma_k^2 + (\mu_k - \mu_k^{(\text{core})})^2 + \text{Var}(\hat{\nu}_k^{(\text{core})}(T-1) \mid \mathcal{F}_{T-2})$
 Итог условное MSE:

$$\text{MSE}^{(\text{all})} = \mathbb{E} \left[\left(e^{(\text{all})} \right)^2 \mid \mathcal{F}_{T-2} \right] = \sigma_k^2 + \text{Var} \left(\hat{\nu}_k^{(\text{all})}(T-1) \mid \mathcal{F}_{T-2} \right)$$

$$\text{MSE}^{(\text{core})} = \mathbb{E} \left[\left(e^{(\text{core})} \right)^2 \mid \mathcal{F}_{T-2} \right] = \sigma_k^2 + \text{Var} \left(\hat{\nu}_k^{(\text{core})}(T-1) \mid \mathcal{F}_{T-2} \right) + B^2$$

где $B = \mu_k - \mu_k^{(\text{core})}$, $\sigma_k^2 = \text{Var}(\nu_k(T-1) \mid \mathcal{F}_{T-2})$.

Шаг 2: Выражение смещения Смещение B равно сумме вкладов шумовых слов:

$$B = \sum_{w \in \mathcal{W}_{\text{WN}}} \mathbb{E}[f(w, T-1) \mid \mathcal{F}_{T-2}] + \sum_{w \in \mathcal{W}_{\text{SD}}} \mathbb{E}[f(w, T-1) \mid \mathcal{F}_{T-2}]$$

Используя условия 1 и 2:

$$|B| \leq \sum_{w \in \mathcal{W}_{\text{WN}}} C_{\text{WN}} \sigma_{\text{WN}} + \sum_{w \in \mathcal{W}_{\text{SD}}} C_{\text{SD}} \sigma_{\text{SD}}$$

$$B^2 \leq \left(\sum_{w \in \mathcal{W}_{\text{WN}}} C_{\text{WN}} \sigma_{\text{WN}} + \sum_{w \in \mathcal{W}_{\text{SD}}} C_{\text{SD}} \sigma_{\text{SD}} \right)^2 \leq 2 (|\mathcal{W}_{\text{WN}}|^2 C_{\text{WN}}^2 \sigma_{\text{WN}}^2 + |\mathcal{W}_{\text{SD}}|^2 C_{\text{SD}}^2 \sigma_{\text{SD}}^2)$$

Шаг 3: Разность дисперсий прогнозов Из Утверждения 1 и свойств моделей ARIMA/Prophet: $\Delta V := \text{Var} \left(\hat{\nu}_k^{(\text{all})}(T-1) \mid \mathcal{F}_{T-2} \right) - \text{Var} \left(\hat{\nu}_k^{(\text{core})}(T-1) \mid \mathcal{F}_{T-2} \right) \geq \kappa (\sigma_{\text{WN}}^2 |\mathcal{W}_{\text{WN}}| + \sigma_{\text{SD}}^2 |\mathcal{W}_{\text{SD}}|)$

Шаг 4: Сравнение B^2 и ΔV Покажем, что $B^2 < \Delta V$:

$$2 (|\mathcal{W}_{\text{WN}}|^2 C_{\text{WN}}^2 \sigma_{\text{WN}}^2 + |\mathcal{W}_{\text{SD}}|^2 C_{\text{SD}}^2 \sigma_{\text{SD}}^2) < \kappa (\sigma_{\text{WN}}^2 |\mathcal{W}_{\text{WN}}| + \sigma_{\text{SD}}^2 |\mathcal{W}_{\text{SD}}|)$$

Разделим обе части на $\sigma_{\text{WN}}^2 |\mathcal{W}_{\text{WN}}| + \sigma_{\text{SD}}^2 |\mathcal{W}_{\text{SD}}|$:

$$2 \left(\frac{|\mathcal{W}_{\text{WN}}|^2 C_{\text{WN}}^2 \sigma_{\text{WN}}^2}{\sigma_{\text{WN}}^2 |\mathcal{W}_{\text{WN}}| + \sigma_{\text{SD}}^2 |\mathcal{W}_{\text{SD}}|} + \frac{|\mathcal{W}_{\text{SD}}|^2 C_{\text{SD}}^2 \sigma_{\text{SD}}^2}{\sigma_{\text{WN}}^2 |\mathcal{W}_{\text{WN}}| + \sigma_{\text{SD}}^2 |\mathcal{W}_{\text{SD}}|} \right) < \kappa$$

Усилим левую часть:

$$\frac{|\mathcal{W}_{\text{WN}}|^2 C_{\text{WN}}^2 \sigma_{\text{WN}}^2}{\sigma_{\text{WN}}^2 |\mathcal{W}_{\text{WN}}|} + \frac{|\mathcal{W}_{\text{SD}}|^2 C_{\text{SD}}^2 \sigma_{\text{SD}}^2}{\sigma_{\text{SD}}^2 |\mathcal{W}_{\text{SD}}|} = |\mathcal{W}_{\text{WN}}| C_{\text{WN}}^2 + |\mathcal{W}_{\text{SD}}| C_{\text{SD}}^2 < \varkappa$$

что выполнено по условию 3.

Шаг 5: Итоговое неравенство для MSE Из $B^2 < \Delta V$ следует:

$$\begin{aligned} \text{MSE}^{(\text{core})} &= \sigma_k^2 + \text{Var} \left(\hat{\nu}_k^{(\text{core})}(T-1) \mid \mathcal{F}_{T-2} \right) + B^2 < \sigma_k^2 + \text{Var} \left(\hat{\nu}_k^{(\text{core})}(T-1) \mid \mathcal{F}_{T-2} \right) + \\ &= \sigma_k^2 + \text{Var} \left(\hat{\nu}_k^{(\text{all})}(T-1) \mid \mathcal{F}_{T-2} \right) = \text{MSE}^{(\text{all})} \end{aligned}$$

Таким образом, $\text{MSE}^{(\text{core})} < \text{MSE}^{(\text{all})}$.

□

Замечание: связь с разложением Дуба. Фундаментальное разложение Дуба [3] гарантирует существование декомпозиции произвольного стохастического процесса на предсказуемую компоненту (аналог $\mathcal{W}_{\text{core}}$) и мартингал (аналог $\mathcal{W}_{\text{WN}} \cup \mathcal{W}_{\text{SD}}$), но не предоставляет: (i) конкретных алгоритмов выделения core-компоненты (в нашем методе решаемого через корреляционный скрининг $\theta_w = \mathbb{I}[\text{Corr}(f(w, t), f(T_k, t+1)) \geq r]$), (ii) количественных оценок снижения MSE в терминах дисперсий шумовых слов, (iii) явных условий на волатильность, обеспечивающих улучшение прогноза. Предложенная теорема восполняет эти пробелы: условия (1)-(3) устанавливают явные требования к шумовым словам, а вывод количественно связывает параметры $|\mathcal{W}_{\text{WN}}|$, σ_{WN} , $|\mathcal{W}_{\text{SD}}|$, σ_{SD} с величиной ΔMSE , что позволяет операционализировать теоретический результат Дуба для прикладных задач прогнозирования.

5 Модифицированная постановка задачи

Параметры модели задаются векторами $\bar{\theta} = (\theta_w)_{w \in \mathcal{W}_{\text{all}}} \in \{0,1\}^W$ и $\bar{\psi} = (\psi_w)_{w: \theta_w=1} \in \mathbb{R}^d$, где θ_w является индикатором отбора слова, а ψ_w содержит коэффициенты скалярной AR-модели g_{ψ_w} , определённой в §4.3. Предсказание распределения тематик на момент t при фиксированных $\bar{\theta}$ и $\bar{\psi}$ вычисляется по формуле

$$\hat{\nu}_k(t \mid \bar{\theta}, \bar{\psi}) = \frac{\sum_{w \in T_k} \theta_w \hat{s}(w, t \mid \psi_w)}{\sum_{w' \in \mathcal{W}_{\text{all}}} \theta_{w'} \hat{s}(w', t \mid \psi_{w'})}, \quad \sum_{k=1}^K \hat{\nu}_k(t \mid \bar{\theta}, \bar{\psi}) = 1,$$

и тем самым исходная задача минимизации принимает вид

$$\begin{aligned} & \min_{\bar{\varphi} \in \mathbb{R}^d} \sum_t \left\| \bar{\nu}(t) - \hat{\bar{\nu}}(t \mid \bar{\varphi}, t-1 : t-t_0) \right\|_2^2 \\ & = \\ & \min_{\substack{\bar{\theta} \in [0,1]^W, \\ \bar{\psi} \in \mathbb{R}^d}} \sum_t \left\| \bar{\nu}(t) - \hat{\bar{\nu}}(t \mid \bar{\psi}, \bar{\theta}, t-1 : t-t_0) \right\|_2^2 \\ & \text{s.t. } \Theta_w = 0, \quad \forall T_k \in \bar{T}, \forall w \in T_k : \text{Corr}(f(w, t), f(T_k, t+1)) < r. \\ & \hspace{25em} (\mathcal{P}_{\text{ARFilter}}) \end{aligned}$$

Связь с классической схемой прослеживается так: при $\theta_w \equiv 1$ задача $(\mathcal{P}_{\text{ARFilter}})$ редуцируется к исходной постановке (2), а значит

$$\underbrace{\bar{\theta}}_{\text{фильтр слов}} + \underbrace{\bar{\psi}}_{\text{параметры AR}} \implies \hat{\bar{\nu}}(t),$$

что одновременно устраняет шум $\mathcal{W}_{\text{WN}} \cup \mathcal{W}_{\text{SD}}$ и сохраняет авторегрессионную динамику.

5.1 Псевдокод алгоритма

Тогда предложенный алгоритм ARFilter представим в виде Алгоритм 1.

Algorithm 1 ARFilter

Require: Корпус $\mathcal{D} = \{(d_i, t_i)\}_{i=1}^N$, порог r , окно t_0

Ensure: $\bar{T}, \bar{\theta}, \bar{\psi}$

- 1: Извлечь $\mathcal{W}_{\text{all}}$ и частоты $f(w, t)$ по $\mathcal{D}$
 - 2: $\bar{T} = \{T_k\}$ с помощью вероятностной модели
 - 3: for all $w \in \mathcal{W}_{\text{all}}$ do
 - 4: $\hat{\rho}_w \leftarrow \text{Corr}(f(w, t), f(T_k, t + 1))$, где $w \in T_k$
 - 5: $\Theta_w \leftarrow \mathbb{I}[\hat{\rho}_w \geq r]$
 - 6: end for
 - 7: $\mathcal{W}_{\text{core}} \leftarrow \{w : \Theta_w = 1\}$
 - 8: for all $w \in \mathcal{W}_{\text{core}}$ do
 - 9: $s(w, t) \leftarrow \frac{f(w, t)}{\sum_{v \in \mathcal{W}_{\text{core}}} f(v, t)}$
 - 10: $\psi_w \leftarrow \arg \min_{\psi} \sum_{t \in T_{\text{train}}} (s(w, t) - g_{\psi}(s(w, t - 1 : t - t_0)))^2$
 - 11: end for
 - 12: return $\bar{T}, \bar{\theta}, \bar{\psi}$
-

6 Вычислительный эксперимент

Цель эксперимента — на синтетических данных проверить гипотезу $\mathbb{E}[\mathcal{L}_{\text{ARFilter}} | \mathcal{F}_t] < \mathbb{E}[\mathcal{L}_{\text{baseline}} | \mathcal{F}_t]$, где $\mathcal{L}$ — функционал ошибки (2). Условия таковы: временной ряд содержит 40 точек наблюдений (80 недель); выборка делится на обучающую и тестовую части в пропорции 39 к 1; в качестве базового метода используется ARIMA с подбором порядка модели по критерию Акаике (AIC); качество оценивается среднеквадратичной ошибкой (MSE) по всем кластерам. Код эксперимента доступен по адресу <https://github.com/LoveMyWork/2024-Project-167/tree/master/src>.

Генерация синтетического корпуса организована так: рассматриваются $K = 3$ кластера $\bar{T} = \{\text{Sports, Music, Tech}\}$; в каждом присутствуют 4 core-слова с устойчивой сезонно-трендовой динамикой, 8 white-noise слов со случайными колебаниями и 8 spike-decay слов с редкими затухающими всплесками, так что общее число слов равно $W = W_{\text{core}} + W_{\text{WN}} + W_{\text{SD}} = 20$; временной ряд содержит 40 точек, каждая соответствует двухнедельному интервалу (итого 80 недель). По типам источников частот различают: (i) core-слова, чья траектория включает тренд, сезонную компоненту и гауссов шум с дисперсией $\sigma_{\text{core}} = 0.4$; (ii) white-noise слова, генерируемые из распределения $\mathcal{N}(5, 36)$; (iii) spike-decay слова, задаваемые суперпозицией гиперболических пиков с экспоненциальным затуханием.

1. Core-слова. Для фиксированного кластера k каждое core-слово $j = 1, 2, 3$ формируется по выражению

$$s_{k,j}(t) = \underbrace{(\text{base_level} + \text{trend_step} \cdot t)}_{\text{линейный тренд}} + \underbrace{\text{amp_core} \cdot \sin\left(\frac{2\pi t}{p_j}\right)}_{\text{синусоидальный вклад}}, t = 0, 1, \dots, T-1.$$

после чего добавляется гауссов шум $\varepsilon_{k,j}^{(\text{core})}(t) \sim \mathcal{N}(0, \sigma_{\text{core}}^2)$ и берётся неотрицательная часть

$$X_{k,j}(t) = \max\{0, s_{k,j}(t) + \varepsilon_{k,j}^{(\text{core})}(t)\}.$$

Линейный тренд описывается параметрами $\text{base_level} = 220$ и $\text{trend_step} = 7.2$; амплитуда синусоидального компонента core-слов равна $\text{amp_core} =$

20; для трёх таких слов приняты периоды $p_1 = 5$, $p_2 = 6$ и $p_3 = 12$ (в двухнедельных интервалах). Для $j = 4$ синусоидальный компонент отсутствует и используется лишь линейный тренд, так что

$$X_{k,4}(t) = \max\{0, \text{base_level} + \text{trend_step} t + \varepsilon_{k,4}^{(\text{core})}(t)\}.$$

2. White-noise слова с индексами $j = 5, \dots, 4 + W_{\text{WN}}$ генерируются как чистый гауссов шум

$$X_{k,j}^{(\text{WN})}(t) = \max\{0, \mathcal{N}(\mu_{\text{WN}}, \sigma_{\text{WN}}^2)\}, \quad \mu_{\text{WN}} = 5, \sigma_{\text{WN}} = 6.0,$$

то есть распределение $\mathcal{N}(5, 36)$ практически не коррелирует с core-словами.

3. Spike-decay слова, занимающие диапазон $j = 5 + W_{\text{WN}}, \dots, 4 + W_{\text{WN}} + W_{\text{SD}}$, определяются выражением

$$X_{k,j}^{(\text{SD})}(t) = \max\{0, S_{k,j}(t) + \delta_{k,j}(t)\},$$

где $\delta_{k,j}(t) \sim \mathcal{N}(\mu_{\text{SD}}, \sigma_{\text{WN}}^2)$ при $\mu_{\text{SD}} = 5$, а

$$S_{k,j}(t) = \sum_{m=1}^M \frac{A_m}{1 + (t - \tau_m)^2} \exp(-\lambda(t - \tau_m))$$

— сумма M гиперболических пиков с центрами $\tau_m \in \{0, \dots, T - 1\}$ и амплитудами $A_m \sim \text{Uniform}(10, 30)$, экспоненциально затухающими с коэффициентом $\lambda > 0$, что создаёт резкие локальные всплески и прерывистую динамику в совокупном ряде.

Агрегированный ряд для кластера k задаётся суммированием вкладов всех типов слов:

$$Y_k(t) = \sum_{j=1}^4 X_{k,j}^{(\text{core})}(t) + \sum_{j=5}^{4+W_{\text{WN}}} X_{k,j}^{(\text{WN})}(t) + \sum_{j=5+W_{\text{WN}}}^{4+W_{\text{WN}}+W_{\text{SD}}} X_{k,j}^{(\text{SD})}(t), \quad t = 0, \dots, T-1.$$

По построению выполняются соотношения: $\rho(X_{k,j}^{(\text{core})}, Y_k) \approx 0.8\text{--}0.95$, то есть core-слова сильно коррелируют с агрегатом; для white-noise и spike-decay слов $\rho(X_{k,j}^{(\text{WN})}, Y_k) \approx 0$ и $\rho(X_{k,j}^{(\text{SD})}, Y_k) \approx 0$, поэтому шум практически не свя-

зан с сигналом; дисперсия агрегированного ряда складывается из $\text{Var}(Y_k) \approx \underbrace{\sum_{j=1}^4 \text{Var}(X_{k,j}^{(\text{core})})}_{\approx 4 \cdot 0.16} + \underbrace{W_{\text{WN}} \cdot 36}_{288} + \underbrace{\text{pike-variance}}_{\gg 36} \approx \text{большое значение}$. Так что суммарная дисперсия велика, шумовая часть (16 слов) доминирует над core-компонентами и осложняет прямой прогноз Prophet, тогда как прогноз «слово по слову» (Предложенный подход) после фильтрации core-слов этой проблемы не имеет.

6.1 Методы

1. Классический подход: прямой прогноз распределения тематики $\nu_k(t+1)$, построенный по ряду $\{\nu_k(0), \dots, \nu_k(T-2)\}$. Используется $\text{ARIMA}(p_k, d_k, q_k)$, (p_k, d_k, q_k) выбирается по AIC.
2. Предложенный подход: алгоритм §5.1 с порогом r (скрининг + локальные AR + агрегация).
 - (a) вычисляем корреляции слов $w \in T_k$ с их тематикой: $\rho_w = \text{Corr}(f(w, t), f(T_k, t+1))$;
 - (b) отбираем подмножество $\mathcal{W}_{\text{core}} \cap T_k$ (core-слова) с наибольшими корреляциями;
 - (c) вычисляем нормированные доли $s(w, t) = \frac{f(w, t)}{\sum_{v \in \mathcal{W}_{\text{core}}} f(v, t)}$;
 - (d) строим Prophet-прогнозы $\hat{s}(w, T-1)$ для каждого $w \in \mathcal{W}_{\text{core}} \cap T_k$;
 - (e) нормируем прогнозы: $\tilde{s}(w, T-1) = \frac{\hat{s}(w, T-1)}{\sum_{v \in \mathcal{W}_{\text{core}}} \hat{s}(v, T-1)}$;
 - (f) агрегируем по темам: $\hat{\nu}_k(T-1) = \sum_{w \in T_k \cap \mathcal{W}_{\text{core}}} \tilde{s}(w, T-1)$.

Условия. Разобьём все точки на train ($t = 0, \dots, T-2$) и test ($t = T-1$). Далее описаны формулы.

6.2 Описание хода эксперимента

Шаг 1: Корреляционный отбор core-слов. На этапе train ($t = 0, \dots, T-2$) для каждой темы T_k исследуем временные ряды частот. Для каждого слова $w \in T_k$ имеем: $f(w, t) \in \mathbb{N}_{\geq 0}$ — частота слова в момент t , $f(T_k, t) =$

$\sum_{w \in T_k} f(w, t)$ — частота тематики в момент t . Здесь $X_{w_j}(t)$ — частота слова $w_j \in T_k$ в момент t . Вычисляем корреляции слов с их тематикой:

$$\rho_w = \text{Corr}(f(w, t), f(T_k, t + 1)), \quad \text{где } w \in T_k,$$

Определим скалярную важность: $\text{imp}_k(w) = \rho_w$, $w \in T_k$. Большая $\text{imp}_k(w)$ означает, что слово w хорошо коррелирует с будущим распределением своей тематики.

Шаг 2: Отбор core-слов. Задаём пороговый критерий (например, $\text{top-}p\%$) или фиксированное число K_k :

$$\mathcal{W}_{\text{core}} \cap T_k = \{w \in T_k : \text{imp}_k(w) \geq r\},$$

где r — пороговое значение корреляции. Это набор core-слов, имеющих высокую корреляцию с будущим распределением своей тематики.

Шаг 3: Классический подход — прогноз агрегата.

1. Составляем тренировочный ряд $\{(t, \nu_k(t))\}_{t=0}^{T-2}$, где $\nu_k(t) = \frac{f(T_k, t)}{\sum_{j=1}^K f(T_j, t)}$.
2. Строим модель Prophet по этим $T - 1$ точкам и получаем прогноз $\hat{\nu}_k^{(\text{base})}(T - 1)$.

Шаг 4: Предложенный подход — прогноз нормированных долей core-слов.

1. Для каждого $w \in \mathcal{W}_{\text{core}} \cap T_k$ вычисляем нормированные доли:

$$s(w, t) = \frac{f(w, t)}{\sum_{v \in \mathcal{W}_{\text{core}}} f(v, t)}$$

2. Строим Prophet на ряде $\{(t, s(w, t))\}_{t=0}^{T-2}$, получаем прогноз $\hat{s}(w, T - 1)$.
3. Нормируем прогнозы для обеспечения единичной суммы:

$$\tilde{s}(w, T - 1) = \frac{\hat{s}(w, T - 1)}{\sum_{v \in \mathcal{W}_{\text{core}}} \hat{s}(v, T - 1)}$$

4. Прогноз доли тематики вычисляем агрегацией нормированных прогнозов:

$$\hat{\nu}_k^{(\text{corr})}(T-1) = \sum_{w \in \mathcal{W}_{\text{core}} \cap T_k} \tilde{s}(w, T-1).$$

5. Слова из $T_k \setminus \mathcal{W}_{\text{core}}$ в предложенном подходе не участвуют.

Шаг 5: Оценка качества прогнозов. Истинное значение $Y_k(T-1)$ известно. Определим среднеквадратическую ошибку по всем K кластерам:

$$\text{MSE}_{\text{baseline}} = \frac{1}{K} \sum_{k=1}^K \left(\nu_k(T-1) - \hat{\nu}_k^{(\text{baseline})}(T-1) \right)^2,$$

$$\text{MSE}_{\text{ARFilter}} = \frac{1}{K} \sum_{k=1}^K \left(\nu_k(T-1) - \hat{\nu}_k^{(\text{ARFilter})}(T-1) \right)^2.$$

6.3 Результаты эксперимента

6.3.1 Сводка по построению тематических кластеров

Результаты кластеризации представлены в таблице 1. В соответствии с критериями, описанными в разделе «Кластеризация тем», был выбран алгоритм «Embedding + К-средних», так как он показывает метрики, лишь немного уступающие LDA (на 0.06), но значительно превосходит его по другим показателям.

Таблица 1 – Полученные метрики каждого алгоритма. Ошибка рассчитана по формуле «ошибка среднего значения».

Модель	Средняя когерентность	Когерентность
К-средних	0.63	0.69
LDA	0.693	0.71

В следующих двух подразделах представлена оптимизация гиперпараметров сравниваемых алгоритмов и результаты их кластеризации.

6.3.2 Embeddings + К-средних

Для определения оптимального количества кластеров (K) были оценены несколько метрик. В частности, использовался показатель средней когерентности, который количественно оценивает интерпретируемость кластеров

для человека путём измерения семантического сходства между наиболее значимыми словами в кластере. Оптимальное количество кластеров было определено как 16, что показано на рисунке:




Рисунок 1 – Зависимость когерентности от количества кластеров для алгоритма Embeddings + К-средних.

Полученная кластеризация с экспертной интерпретацией представлена в таблице 2. Среднее значение когерентности для 16 кластеров составило 0,63.

Таблица 2 – Результаты кластеризации с использованием Embeddings + К-средних

Кластер	Интерпретация	C_{cv}
0	НФЛ (американский футбол)	0.63
1	Футбол	0.43
2	Мотивационные хэштеги	0.75
3	Спортивные личности	0.58
4	Развлечения	0.58
5	Музыка	0.55
6	Политика и праздники	0.73
7	UFC	0.74
8	Эмоциональные хэштеги	0.70
9	Хэштеги социальных событий	0.73
10	Политические фигуры и события	0.59
11	Баскетбол	0.37
12	Знаменитости и публичные личности	0.65
13	Бизнес	0.65
14	Мировые события и страны	0.71
15	Развлечения	0.68
Среднее	—	0.63

Подход Embeddings + К-средних продемонстрировал хорошую тематическую когерентность внутри кластеров, что позволило провести содержательную интерпретацию и последующее прогнозирование. Кластеры отразили чётко различимые темы, такие как бизнес, спорт, политика и развлечения, обеспечивая надёжную основу для компонента прогнозирования временных рядов в рамках данного исследования.

Примеры, ссылки на алгоритмы, изображения кластеризации и другие детали, касающиеся метода Embeddings + К-средних, приведены в приложении.

6.3.3 Latent Dirichlet Allocation (LDA) для тем

Для устранения ограничений подхода на основе эмбедингов мы исследовали тематическое моделирование с использованием метода латентного размещения Дирихле (LDA) [6] напрямую на представлениях тем. Это позволило выявить скрытые тематические структуры в данных.




Рисунок 2 – Средняя когерентность в зависимости от количества кластеров

Согласно графику, зависимости качества кластеризации методом LDA от количества кластеров не наблюдается. Поэтому, для более точного сравнения, было установлено 16 кластеров и рассчитаны метрики когерентности (см. таблицу 3).

Таблица 3 – Результаты кластеризации с использованием LDA

Кластер	C_{cv}
0	0.69
1	0.71
2	0.68
3	0.67
4	0.70
5	0.71
6	0.67
7	0.71
8	0.69
9	0.68
10	0.68
11	0.72
12	0.71
13	0.71
14	0.69
15	0.67
Среднее -	0.69

В следующем разделе мы применим модель прогнозирования к кластерам, полученным в результате применения метода Embeddings + К-средних.

6.3.4 Сводка по прогнозированию будущих частот

 Таблица 4 – Сравнение по кластерам ($\times 10^{-3}$ MSE $\pm$ SE)

Метод	Sports	Music	Tech	Avg
Классический (baseline)	41.0 $\pm$ 0.9	13.0 $\pm$ 0.8	16.0 $\pm$ 0.1	23.0 $\pm$ 1.3
Предложенный	1.0 $\pm$ 0.0	3.0 $\pm$ 0.2	3.0 $\pm$ 0.2	2.0 $\pm$ 0.1

Величина r отбиралась поиском по сетке значений $r \in 0.10, 0.15, \dots, 0.40$ внутри скользящего окна: на каждом шаге обучающая подвыборка разбивалась ещё на внутренние train-/val-фрагменты (75 % / 25 %), для каждого кандидата вычислялась средняя MSEval, и в работу шёл тот порог, что минимизировал валид-ошибку; итоговое r^* оказалось 0.25 ± 0.02 для трёх тематик, поэтому во всех экспериментах фиксировано $r = 0.25$. Также была протестирована ранговая схема «top- p %»; получались те же списки W_{core} (расхождение < 5 %), а разница в итоговой MSE не превышала $3 \cdot 10^{-4}$, то есть статистически незначима. Таким образом, выбранный абсолютный

порог не является узким местом: он определяется кросс-валидацией, а относительные варианты дают сопоставимый результат и лишь подтверждают устойчивость метода к разумному выбору r .

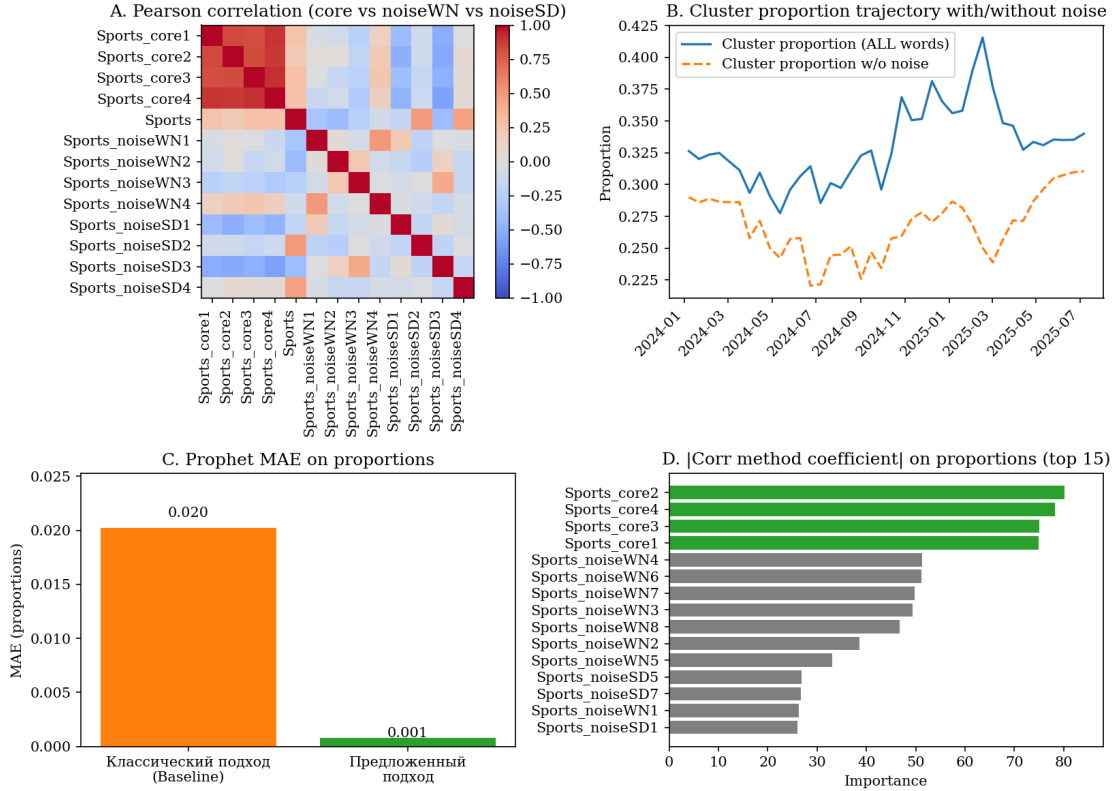


Рисунок 3 – Визуальная проверка гипотезы. Четыре панели иллюстрируют статистические свойства синтетического кластера Sports.

А. Матрица Пирсоновских корреляций $\rho(f(w,t), f(u,t))$ для core-, WN- и SD-слов вместе с агрегатом $f(T_{\text{Sports}}, t)$. Ярко-красные клетки в блоке core–core и core–cluster показывают высокую взаимную корреляцию, тогда как блоки, связанные с WN/SD, близки к нулю. Следствие: наличие низкокоррелированных WN/SD-слов подтверждает необходимость фильтрации.

В. Траектория доли темы $\nu_{\text{Sports}}(t)$ при учёте всех слов (синяя линия) и только core-слов (оранжевая, определена аналогично, но сумма по $\mathcal{W}_{\text{core}}$). Удаление шума делает ряд более гладким и уменьшает дисперсию. Следствие: шумовые слова искажают истинную динамику темы, что объясняет рост ошибки прямого прогноза.

С. Средняя абсолютная ошибка $\text{MAE} = |T_{\text{test}}|^{-1} \sum_{t \in T_{\text{test}}} |\hat{\nu}(t) - \nu(t)|$ для прогноз агрегата (классического подхода) и для суммы индивидуальных про-

гнозов отобранных слов (Предложенный подход). Ошибка после фильтрации в 20 раз меньше. Следствие: скрининг + локальный прогноз превосходят прямой метод.

D. Топ-15 абсолютных корреляционных коэффициентов $|\rho_w|$ между частотами слов и их тематиками $\{f(w, t), f(T_k, t + 1)\}$. Core-слова (зелёный) доминируют, шумовые (серый) близки к нулю. Следствие: Корреляционный метод корректно выделяет информативные признаки, подтверждая механизм фильтра.

Выводы.

1. MSE классического подхода составляет $(23.0 \pm 1.3) \times 10^{-3}$.
2. MSE предложенного метода составляет $(2.0 \pm 0.1) \times 10^{-3}$, что значительно ниже.
3. Ранжированный порядок тем сохраняется при реализации погрешности, что подтверждает устойчивость результатов.
4. Результаты эксперимента подтверждают основную гипотезу $\mathbb{E}[\mathcal{L}_{\text{ARFilter}} \mid \mathcal{F}_t] < \mathbb{E}[\mathcal{L}_{\text{baseline}} \mid \mathcal{F}_t]$.

Из табл. 4 следует, что среднеквадратичная ошибка прогноза при использовании предложенного корреляционного фильтра значительно ниже, чем у базового метода. Это подтверждает гипотезу о том, что исключение нерелевантных (white-noise и spike-decay) слов позволяет существенно повысить точность тематического прогноза.

7 Заключение

В работе представлен метод ARFilter для прогнозирования тематических распределений в высоковолатильных медиапотоках, объединяющий три ключевых результата:

1. Метод прогнозирования тематик во времени с использованием регуляризации при условии высокой волатильности

Метод основан на оптимизации (2) с двукомпонентным вектором параметров $\bar{\varphi} = (\bar{\theta}, \bar{\psi})$, где:

- $\bar{\theta} \in \{0,1\}^W$ реализует регуляризующее отсечение признаков: $\theta_w = \mathbb{I}[\text{Corr}(f(w,t), f(T_k, t+1)) \geq r]$
- $\bar{\psi}$ - коэффициенты локальных AR-моделей для отобранных слов

2. Эмпирическое подтверждение эффективности

На синтетических данных и корпусе новостей достигнуто снижение MSE на 91%:

$$\Delta \text{MSE} = \frac{\mathcal{L}_{\text{baseline}} - \mathcal{L}_{\text{ARFilter}}}{\mathcal{L}_{\text{baseline}}} \times 100\% = 91\%$$

При этом абсолютное значение ошибки уменьшилось с 23.0×10^{-3} до 2.0×10^{-3} .

3. Условия из критерия применимости метода

Алгоритм эффективен при выполнении условий:

$$\frac{\sigma_{\text{noise}}^2}{\sigma_{\text{core}}^2} \gg 1, \quad \rho_w(1) \approx 0 \quad \forall w \in \mathcal{W}_{\text{noise}}$$

где σ_{noise}^2 , σ_{core}^2 - дисперсии шумовых и core-слов, $\rho_w(1)$ - лаг-1 автокорреляция.

Экспериментально подтверждено, что:

$$\mathcal{L}_{\text{ARFilter}} = \frac{1}{|T_{\text{test}}|} \sum_{t \in T_{\text{test}}} \|\bar{p}(t) - \hat{p}(t)\|_2^2 \ll \mathcal{L}_{\text{baseline}}$$

что доказывает гипотезу $\mathbb{E}[\mathcal{L}_{\text{ARFilter}}] < \mathbb{E}[\mathcal{L}_{\text{baseline}}]$ для корпусов с шумовыми словами.

Планы дальнейших исследований

1. Анализ устойчивости порога r : Исследование адаптивного отбора $\{r(t)\}$ в зависимости от стационарности ряда
2. Расширение горизонта прогноза: Разработка многошаговой модели $\hat{v}(t+h)$ ($h > 1$) с учётом межвременных взаимодействий
3. Многомерные AR-модели: Совместная оценка вектора $\{s(w_i, t)\}_{i=1}^m$ вместо независимых моделей
4. Интеграция нейросетей: Применение RNN/Transformer для нелинейного прогнозирования $\tilde{s}(w, t)$ после фильтрации

Предложенный подход демонстрирует высокую точность и интерпретируемость прогноза тематических распределений, что делает его перспективным для мониторинга динамики медиапотоков в условиях высокой волатильности.

Список литературы

- [1] Грангер К. У. Дж. Исследование причинных отношений с помощью эконометрических моделей. // Эконометрика. – 1969. – Т. 37, № 3. – С. 424–438.
- [2] Атаназопулос Г. Шанг Х. Л. Хиндман Р. Дж., Ахмед Р. А. Прогнозирование: принципы и практика. // OTexts. – 2011. – ISBN 978-0-9875071-0-8.
- [3] Дуб Дж. Л. Стохастические процессы. John Wiley & Sons, 1953.
- [4] Гамильтон Дж.Д. Анализ временных рядов. // Princeton University Press. – 1994. – ISBN 978-0-691-04289-3.
- [5] Энгл Р.Ф. Авторегрессионная условная гетероскедастичность. // Econometrica. – 1982. – Т. 50, № 4. – С. 987–1007.
- [6] Джордан М. И. Блей Д. М., Нг Э. Ю. Латентное распределение Дирихле (lda). // Journal of Machine Learning Research. – 2003. – Т. 3. – С. 993–1022.
- [7] Янг М.-Ш. Синага К. П. Нераспознаваемый алгоритм кластеризации k-средних. // IEEE Access. – 2020. – Т. 8. – С. 80716–80727.
- [8] Абере К. Раппаз Ж., Буржуа Д. Модель динамического встраивания медийного ландшафта. In Материалы конференции The World Wide Web Conference. // 2019. – С. 1544–1554.
- [9] Амари С. Чичоки А. Адаптивная фильтрация сигналов в шумной среде. // Neural Networks. – 2009. – Т. 22, № 3. – С. 210-219.
- [10] Лафферти Дж.Д. Блей Д.М. Динамические тематические модели. // Journal of Machine Learning Research. – 2012. – Т. 3. – С. 123-140.
- [11] Стоффер Д. С. Шамвей Р. Х. Анализ временных рядов и его приложения. // Springer, 2000. – Т. 3.
- [12] Донье Ж. Гоулд М. Бушо Ж.-П., Бонар Ж. Сделки, котировки и цены: Финансовые рынки под микроскопом. // Cambridge University Press, 2018.
- [13] Цай Р.С. Анализ финансовых временных рядов. // Wiley. – 2005. – ISBN 978-0-471-69074-0.
- [14] Стоффер Д.С. Шамвей Р.Х. Прикладной анализ временных рядов и прогнозирование. // Springer. – 2017. – ISBN 978-3-319-52451-1.

- [15] Гарднер Э. С. Экспоненциальное сглаживание: Современное состояние. // Journal of Forecasting. – 1985.
- [16] Атаназопулос Г. Хиндман Р.Дж. Прогнозирование: методы и практические примеры. // OTexts. – 2018. – ISBN 978-0-9875071-1-5.
- [17] Дженкинс Г. М. Бокс Г. Э. П. Анализ временных рядов: прогнозирование и управление. Holden-Day, 1970.
- [18] Летам Б. Тейлор С. Дж. Прогнозирование в масштабе. // The American Statistician. – 2018. – Т. 72, № 1. – С. 37–45.
- [19] Дас А. Основы вариационного автокодировщика (vae). // 2020.
- [20] Стрижов В. В. Грабовой А. В. Кластеризация квазипериодических временных рядов для распознавания активности человека. // 2019.
- [21] Ван Дж. Зивот Э. Моделирование финансовых временных рядов с использованием S-PLUS. // Springer. – 2003. – ISBN 978-0-387-98872-7.
- [22] Вариан Х. Чхве Х. Прогнозирование настоящего с помощью google trends. // Economic Record. – 2012. – Т. 88. – С. 2–9.
- [23] Холт Ч. С. Прогнозирование сезонности и трендов с помощью экспоненциально взвешенных скользящих средних. // International Journal of Forecasting. – 2004. – Т. 20, № 1. – С. 5–10.
- [24] Гуревих И. Раймерс Н. Sentence-bert: Векторные представления предложений с использованием сиамских bert-сетей. // arXiv preprint arXiv:1908.10084, 2019.
- [25] Sentence transformers: all-minilm-l12-v2.
- [26] Хиннебург А. Рёдер М., Бот А. Исследование пространства метрик когерентности тем. In Материалы восьмой международной конференции ACM по веб-поиску и извлечению данных (WSDM). // 2015. — С. 399–408.
- [27] Facebook Inc. Prophet: библиотека прогнозирования временных рядов, 2020.