

Аннотация

Рассматривается задача краткосрочного прогноза вектора долей тем $\vec{\nu}(t)$ в медиапотоке. Показано, что классическая AR-модель деградирует при наличии слов-шума (white-noise, spike-decay). Предлагается двухшаговый метод: (i) корреляционный скрининг слов по критерию $\rho_w = \text{Corr}(f(w,t), f(w,t+1))$; (ii) локальный AR-прогноз для отобранных признаков и агрегация. На синтетическом и новостном корпусах метод снижает MSE прогноза более чем в десять раз по сравнению с базовой ARIMA, тем самым подтверждая гипотезу о полезности фильтрации низкокоррелированных слов. Метод не зависит от выбора AR-ядра и применим в потоках высокой волатильности.

Ключевые слова: Набор временных рядов · Волатильность · Корреляционный фильтр · PLS · Тематическое моделирование · ARIMA.

Содержание

1	Введение	4
2	Постановка задачи прогнозирования тематических рядов	7
3	Построение тематических кластеров	10
4	Модель прогноза будущих частот	14
4.1	Классический авторегрессионный подход	14
4.2	Проблемы и ограничения классического подхода	18
4.3	Альтернативный корреляционный подход	21
5	Модифицированная постановка задачи	26
5.1	Псевдокод алгоритма	27
6	Вычислительный эксперимент. Синтетический генератор и статистические свойства данных	28
6.1	Генерация данных	28
6.2	Методы	30
6.3	Описание хода эксперимента	31
6.4	Результаты эксперимента	33
6.4.1	Сводка по построению тематических кластеров	33
6.4.2	Embeddings + К-средних	33
6.4.3	Latent Dirichlet Allocation (LDA) для тем	35
6.4.4	Сводка по прогнозированию будущих частот	36
6.5	Выводы	38
7	Выносятся на защиту	39
8	Заключение	40

1 Введение

Способность точно прогнозировать тематические распределения в медиапотоках представляет собой критически важную задачу для современных приложений в маркетинге, медиапроизводстве и исследованиях инноваций. Несмотря на значительный прогресс в методах анализа временных рядов и тематического моделирования, существующие подходы демонстрируют ограниченную эффективность при работе с высоковолатильными текстовыми данными, где присутствие шумовых слов существенно снижает точность прогнозов. Данная работа предлагает метод ARFilter, сочетающий тематическое моделирование с динамической фильтрацией волатильных компонент, что обеспечивает снижение среднеквадратичной ошибки на 91% относительно классических подходов при сохранении интерпретируемости результатов.

Ключевыми для понимания работы являются следующие понятия: медиапоток как хронологическая последовательность документов $\mathcal{D} = \{(d_i, t_i)\}_{i=1}^N$, словарь $\mathcal{W}_{\text{all}}$ — множество n -грамм ($1 \leq n \leq 4$), тематика $T_k \subset \mathcal{W}_{\text{all}}$ — семантический кластер слов, образующий разбиение словаря, и доля темы $\nu_k(t) = \frac{f(T_k, t)}{\sum_j f(T_j, t)}$, где $f(w, t)$ — частота слова в момент времени t . Тематическое моделирование понимается как метод выявления скрытой тематической структуры в текстовых корпусах.

Основная идея метода заключается в комбинации динамического отбора слов по их корреляции с будущим распределением тематик и иерархического прогнозирования нормированных частот отобранных core-слов с последующей агрегацией на уровне тематик. Этот подход основан на фундаментальных принципах причинного анализа Грангера [?], обеспечивающего теоретическую базу для отбора информативных признаков, иерархического прогнозирования [?], демонстрирующего эффективность композитных моделей, и теории разложения стохастических процессов Дуба [?], предоставляющей математический аппарат для разделения детерминированных и стохастических компонент временных рядов :cite[1]:cite[5].

Связь с разложением Дуба: В контексте нашей работы ядро метода ARFilter ($\mathcal{W}_{\text{core}}$) соответствует предсказуемой компоненте в разложении Дуба, характеризующей устойчивые тренды и сезонные паттерны частот

слов. Шумовые компоненты ($\mathcal{W}_{\text{WN}} \cup \mathcal{W}_{\text{SD}}$) аналогичны мартингальной составляющей, описывающей непредсказуемые флуктуации с нулевым математическим ожиданием приращений. Теорема Дуба формализует принцип декомпозиции процесса $X_t = A_t + M_t$, где: - A_t — предсказуемый процесс (аналог $\sum_{w \in \mathcal{W}_{\text{core}}} f(w, t)$) - M_t — мартингал (аналог $\sum_{w \in \mathcal{W}_{\text{noise}}} f(w, t)$) :cite[1]

Развитие этих идей прослеживается в работах по тематическому моделированию [3, 11], обеспечивших переход от анализа отдельных слов к семантическим кластерам, и исследованиях волатильности медиаданных [7], выявивших проблему шумовых слов. Параллельно развитие методов анализа временных рядов [4, 14] показало потенциал комплексных подходов, однако их применение к тематическим распределениям оставалось неисследованным, а перенос принципов фильтрации [9] на высокоразмерные текстовые данные требовал адаптации к специфике композиционных рядов.

Современное состояние области характеризуется рядом ограничений. Традиционные методы прогнозирования (ARIMA [?], экспоненциальное сглаживание [9], Prophet [12]) работают с единичными рядами и чувствительны к волатильности медиаданных [7]. Подходы на основе нейронных сетей [2] и вариационных автокодировщиков теряют интерпретируемость и требуют больших объемов данных. Методы кластеризации временных рядов [5] и тематического моделирования [3, 11] решают частичные задачи, но не обеспечивают комплексного прогноза распределений. Попытки прогнозирования трендов [10, 13] либо игнорируют тематический контекст, либо используют статическую фильтрацию, неадаптивную к изменению структуры шума, что особенно проблематично при наличии white-noise и spike-decay слов, вызывающих рост дисперсии и падение автокорреляции тематических рядов ($\rho_k(1) < 0.3$).

Для преодоления этих ограничений предлагается метод ARFilter, вводящий два ключевых механизма: корреляционный фильтр $\theta_w = \mathbb{I}[\text{Corr}(f(w, t), \nu_k(t + 1)) \geq r]$ для динамического отбора слов и иерархическую агрегацию $\hat{\nu}_k(t + 1) = \sum_{w \in T_k} \theta_w g_{\psi_w}(s(w, t))$ для построения прогноза. Преимущества метода включают точность (снижение MSE с 23.0×10^{-3} до 2.0×10^{-3} относительно ARIMA) и совместимость с различными AR-моделями и кластеризаторами (LDA, K-Means). Основное ограничение —

необходимость кросс-валидации для выбора порога r — компенсируется теоретическими гарантиями (Теорема Задворнова) и экспериментальной эффективностью.

Научная новизна работы заключается в трех аспектах: новый критерий отбора слов по корреляции с будущим распределением тематик (а не с собственным будущим), теоретическое доказательство снижения MSE при фильтрации волатильных слов, и адаптация аппарата разложения Дуба к задаче фильтрации семантических шумов в композиционных временных рядах. Потенциальное влияние включает приложения в маркетинге для сегментированных аудиторий, социологии для анализа общественных трендов и наукометрии для прогнозирования научных направлений, обеспечивая универсальный инструмент для работы с высоковолатильными распределениями в динамически меняющихся средах.

2 Постановка задачи прогнозирования тематических рядов

Дано. Рассматривается конечное множество тематик (кластеров) $\bar{T} = \{T_1, \dots, T_K\}$ и словарь $\mathcal{W}_{\text{all}}$, содержащий $W = |\mathcal{W}_{\text{all}}|$ слов. Каждой тематике T_k соответствует подмножество слов $T_k \subset \mathcal{W}_{\text{all}}$, такие что:

$$T_i \cap T_j = \emptyset \text{ при } i \neq j, \quad \bigcup_{k=1}^K T_k = \mathcal{W}_{\text{all}}.$$

Для каждого слова $w \in \mathcal{W}_{\text{all}}$ и момента времени $t \in \{0, \dots, T-1\}$ задана частота $f(w, t) \in \mathbb{R}_{\geq 0}$, соответствующая числу вхождений слова w в тематическом потоке текстов в момент t .

Агрегированная частота тематики T_k :

$$f(T_k, t) := \sum_{w \in T_k} f(w, t).$$

Доля темы T_k среди всех тем в момент времени t :

$$\nu_k(t) := \frac{f(T_k, t)}{\sum_{j=1}^K f(T_j, t)}, \quad \text{а вектор долей: } \bar{\nu}(t) := (\nu_1(t), \dots, \nu_K(t)) \in \Delta^K,$$

где $\Delta^K := \left\{ \mathbf{x} \in \mathbb{R}^K \mid x_k \geq 0, \sum_{k=1}^K x_k = 1 \right\}$ — стандартный симплекс размерности $K-1$.

Вероятностная модель. Рассматриваем последовательность наблюдений как реализацию случайного процесса, где прогнозное распределение представляет собой условное математическое ожидание:

$$\hat{\nu}_k(t) := \mathbb{E}[\nu_k(t) \mid \mathcal{F}_{t-1}],$$

где $\mathcal{F}_{t-1}$ - σ -алгебра, порожденная наблюдениями до момента t .

Для гарантии нахождения прогнозов в симплексе накладываем условие на ковариационную матрицу шума:

$$\|\Sigma\|_F < \varepsilon \min_j \mu_j,$$

где $\|\cdot\|_F$ - норма Фробениуса, μ_j - математическое ожидание j -й компоненты.

Ограничения и свойства данных.

1. $f(w, t) \in \mathbb{R}_{\geq 0}, \quad \forall w \in \mathcal{W}_{\text{all}}, \forall t \in \{0, \dots, T-1\},$
2. $\nu_k(t) := \frac{f(T_k, t)}{\sum_{j=1}^K f(T_j, t)}, \quad \bar{\nu}(t) := (\nu_1(t), \dots, \nu_K(t)) \in \Delta^K,$
3. При малых значениях $f(w, t) \ll 1$ допускается: $\text{Var}[f(w, t)] \gg 0.$

Модель и решение.

- Модель: отображение

$$\mathcal{M}_{\bar{\varphi}} : \mathcal{H} \rightarrow \Delta^K,$$

где $\mathcal{H} := \{f(w, t-1), \dots, f(w, t-t_0)\}_{w \in \mathcal{W}_{\text{all}}}$ — историческая матрица частот слов, $\bar{\varphi} \in \mathbb{R}^d$ - параметры модели.

- Критерий: выбор квадратичной функции потерь обусловлен предположением о нормальности распределения ошибок прогноза:

$$\mathcal{L}(\bar{\varphi}) := \frac{1}{|T_{\text{test}}|} \sum_{t \in T_{\text{test}}} \left\| \bar{\nu}(t) - \hat{\bar{\nu}}(t \mid \bar{\varphi}) \right\|_2^2.$$

- Решение: оптимальные параметры находятся как решение задачи минимизации:

$$\min_{\bar{\varphi} \in \mathbb{R}^d} \frac{1}{|T_{\text{test}}|} \sum_{t \in T_{\text{test}}} \left\| \bar{\nu}(t) - \hat{\bar{\nu}}(t \mid \bar{\varphi}, t-1, \dots, t-t_0) \right\|_2^2.$$

Стратегия валидации. Выборка $\{0, \dots, T-1\}$ разбивается на обучающую (T_{train}) и тестовую (T_{test}) части. Предлагается использовать стратегию скользящего окна: модель обучается на $[t-t_0, t-1]$, проверяется на t .

Цель - построить устойчивую модель прогноза распределения частот тематик в условиях аномальных значений и циклических изменений.

3 Построение тематических кластеров

Задача. Пусть $\mathcal{W}_{\text{all}} = \{w_1, \dots, w_W\}$ – словарь n -грамм ($1 \leq n \leq 4$). Требуется построить разбиение $\bar{T} = \{T_1, \dots, T_K\}$ такое, что $T_i \cap T_j = \emptyset$, $\bigcup_{k=1}^K T_k = \mathcal{W}_{\text{all}}$.

Мы применили многокомпонентный подход к кластеризации временных рядов, протестировав несколько техник с целью выявления наиболее эффективного метода. Ниже представлены два лучших подхода:

- Встраивания + К-средних (Embeddings + K-Means)
- Тематическое моделирование тем с использованием латентного размещения Дирихле (Latent Dirichlet Allocation, LDA)

Метод 1 (Embeddings+ k -means). Определяется отображение

$$E : \mathcal{W}_{\text{all}} \rightarrow \mathbb{R}^d, \quad E(w) = \mathbf{e}_w$$

(модель all-MiniLM-L12-v2). Для заданного K' решается

$$\min_{\{\mathbf{T}_k\}_{k=1}^{K'}} \sum_{k=1}^{K'} \sum_{w \in T_k} \|\mathbf{e}_w - \boldsymbol{\mu}_k\|_2^2, \quad \boldsymbol{\mu}_k = \frac{1}{|T_k|} \sum_{w \in T_k} \mathbf{e}_w.$$

Ключевыми шагами первого подхода являются генерация встраиваний (embeddings), которая осуществляется с использованием библиотеки Sentence Transformers [6] для создания контекстуальных встраиваний каждой темы на основе модели all-MiniLM-L12-v2 [1], а затем применяется кластеризация методом К-средних к полученным встраиваниям тем [11]. Поскольку оба алгоритма являются хорошо известными, мы не приводим их подробное описание в данной работе, ограничиваясь лишь ссылками на источники.

Метод 2 (Latent Dirichlet Allocation). Второй алгоритм работает следующим образом. Этапы предварительной обработки включают лемматизацию, удаление стоп-слов и отбор слов длиной от 2 до 3 символов. Затем создаётся модель LDA [3].

Модель латентного размещения Дирихле (Latent Dirichlet Allocation, LDA) — это вероятностная модель тем, позволяющая выявлять скрытые (латентные) темы в коллекции текстовых документов. Модель LDA основывается на предположении, что каждый документ является смесью нескольких тем, а каждое слово в документе принадлежит одной из этих тем.

Алгоритм LDA включает следующие шаги:

- Для каждой темы $k \in \{1, \dots, K'\}$:
 - Выбрать распределение слов $\varphi_k \sim \text{Dirichlet}(\beta)$, где β — гиперпараметр, задающий априорное распределение Дирихле для распределений слов.
- Для каждого документа $d \in \{1, \dots, D\}$:
 - Выбрать распределение тем $\theta_d \sim \text{Dirichlet}(\alpha)$, где α — гиперпараметр, задающий априорное распределение Дирихле для распределений тем.
 - Для каждого слова w_{dn} в документе d :
 - * Выбрать тему $z_{dn} \sim \text{Multinomial}(\theta_d)$
 - * Выбрать слово $w_{dn} \sim \text{Multinomial}(\varphi_{z_{dn}})$

Совместное распределение всех переменных модели (распределения тем θ , распределения слов φ , назначенные темы $\mathbf{z}$ и наблюдаемые слова $\mathbf{w}$) можно записать следующим образом:

$$p(\theta, \varphi, \mathbf{z}, \mathbf{w} \mid \alpha, \beta) = \prod_{k=1}^{K'} p(\varphi_k \mid \beta) \prod_{d=1}^D p(\theta_d \mid \alpha) \prod_{n=1}^{N_d} p(z_{dn} \mid \theta_d) p(w_{dn} \mid \varphi_{z_{dn}}) \quad (1)$$

Задача вывода в модели LDA заключается в нахождении апостериорного распределения скрытых переменных (θ , φ и $\mathbf{z}$) при заданных наблюдаемых словах $\mathbf{w}$ и гиперпараметрах α и β . Поскольку точный вывод в этой модели является вычислительно сложным, на практике применяются приближённые методы.

Кластеризация производится правилом $w \mapsto T_{\arg \max_k \theta_{w,k}}$.

Оптимальное число кластеров K . Для определения оптимального числа кластеров K используется мера средней когерентности C_{cv} [8], которая оценивает интерпретируемость кластеров для человека путём измерения семантического сходства между словами внутри кластера:

$$K = \arg \min_{K' \in \mathbb{N}} \frac{1}{K'} \sum_{m=0, \dots, K'-1} C_{cv}(c_m) \quad (2)$$

Мера C_{cv} рассчитывается следующим образом:

$$C_{cv} = \frac{1}{|S_{\text{set}}^{\text{one}}|} \sum_{(W_0, W_*) \in S_{\text{set}}^{\text{one}}} \tilde{m}_{\cos(\text{nlr}, 1)}(W_0, W_*) \quad (3)$$

где $S_{\text{set}}^{\text{one}} = \{(W_0, W_*) \mid W_0 = \{w_i\}, w_i \in W, W_* = W\}$ — это сегментация, представляющая множество пар подмножеств слов, а $\tilde{m}_{\cos(\text{nlr}, 1)}(W_0, W_*)$ — косинусное сходство между контекстными векторами W_0 и W_* , оценивающее, насколько хорошо W_* «объясняет» W_0 .

Выбор метода. Цель данного раздела — сравнить описанные подходы по качеству кластеризации и выбрать один из них для использования в разделе Прогнозирования. Был разработан следующий критерий выбора наилучшего алгоритма из двух, основанный на метрике когерентности:

Пусть $(C_{cv}^{\text{Emb}}, C_{cv}^{\text{LDA}})$ — когерентности при K^* .

$$\text{Модель} = \begin{cases} \text{Embeddings}+k\text{-means}, & |C_{cv}^{\text{Emb}} - C_{cv}^{\text{LDA}}| < 0.1 \text{ и } C_{cv}^{\text{Emb}} > 0.5, \\ \text{LDA}, & \text{иначе.} \end{cases}$$

Таким образом, мы допускаем небольшое снижение метрики у алгоритма k -means по сравнению с LDA, поскольку он является более простым и превосходит LDA по другим параметрам.

Тематические ряды. Для $t \in \{0, \dots, T-1\}$ и $T_k \in \overline{T}$ определяется

$$f(T_k, t) = \sum_{w \in T_k} f(w, t), \quad \nu_k(t) = \frac{f(T_k, t)}{\sum_{j=1}^K f(T_j, t)}.$$

Получены ряды $\{f(T_k, t)\}_t$, используемые далее в прогнозе.

4 Модель прогноза будущих частот

4.1 Классический авторегрессионный подход

В классическом случае используется подход, основанный на авторегрессионной модели (AR-model), прогнозирующей частоты тематик в зависимости от их значений в предыдущие отчёты. Для этого строиться AR-model по типу ARIMA, например, через реализацию Prophet.

Скалярные ряды. Для каждой тематики $T_k \in \overline{T}$ задан ряд

$$y_k(t) := \nu_k(t), \quad t \in \{0, \dots, T-1\},$$

где $\nu_k(t)$ определена в (??).

SARIMA(p_k, d_k, q_k) для долей. Пусть B — оператор сдвига $B^j y_k(t) = y_k(t - j)$.

Модель SARIMA (Seasonal Autoregressive Integrated Moving Average — сезонная авторегрессионная интегрированная скользящая средняя) представляет собой расширение модели ARIMA, учитывающее сезонность во временных рядах. Модель $SARIMA(p, d, q)(P, D, Q)_m$ может быть представлена следующим образом:

$$(1 - \varphi_1 B)(1 - \Phi_1 B^m)(1 - B)^d(1 - B^m)^D y_t = (1 + \theta_1 B)(1 + \Theta_1 B^m) \varepsilon_t \quad (4)$$

где p - порядок несезонной авторегрессии, d - порядок несезонного дифференцирования, q - порядок несезонного скользящего среднего, P - порядок сезонной авторегрессии, D - порядок сезонного дифференцирования, Q - порядок сезонного скользящего среднего, m - количество периодов в сезонном цикле, φ_1 - параметр несезонной авторегрессии, Φ_1 - параметр сезонной авторегрессии, θ_1 - параметр несезонного скользящего среднего, Θ_1 - параметр сезонного скользящего среднего, B - оператор сдвига назад ($B^j y_t = y_{t-j}$), а ε_t - белый шум.

Алгоритм SARIMA включает следующие этапы:

1. Идентификация модели: Определение значений p, d, q, P, D, Q и m на основе анализа функций автокорреляции (ACF) и частичной автокорреляции (PACF), а также проведения тестов на стационарность.

2. Оценка параметров: Оценивание параметров $\varphi_1, \Phi_1, \theta_1, \Theta_1$ и дисперсии шума σ^2 с использованием метода максимального правдоподобия или метода условных наименьших квадратов.

3. Диагностика модели: Проверка адекватности модели путём анализа остатков на наличие автокорреляции, нормальности распределения и гомоскедастичности.

4. Прогнозирование: Получение точечных и интервальных прогнозов на основе оценённой модели:

$$\hat{y}_{t+h|t} = \varphi_1 \hat{y}_{t+h-1|t} + \Phi_1 \hat{y}_{t+h-m|t} - \theta_1 \hat{\varepsilon}_{t+h-1|t} - \Theta_1 \hat{\varepsilon}_{t+h-m|t} \quad (5)$$

где $\hat{\varepsilon}_{t+h|t} = 0$ при $h > 0$.

Точечный прогноз.

$$\hat{y}_k(t+1) := \mathbb{E}_{\hat{\psi}_k}[y_k(t+1) \mid \mathcal{F}_t].$$

Нормировка. Для обеспечения принадлежности $\hat{\bar{v}}(t+1) \in \Delta^K$ выполняется

$$\hat{v}_k(t+1) = \frac{\hat{y}_k(t+1)}{\sum_{j=1}^K \hat{y}_j(t+1)}.$$

Функционал качества. В качестве метрик качества прогноза временных рядов используются средняя абсолютная ошибка (MAE) и среднеквадратичная ошибка (MSE):

$$\mathcal{L}_{\text{ARIMA}} = \frac{1}{|T_{\text{test}}|} \sum_{t \in T_{\text{test}}} \|\bar{v}(t) - \hat{\bar{v}}(t)\|_2^2.$$

Практическая реализация. Подбор (p_k, d_k, q_k) и вычисление $\hat{y}_k(t+1)$ осуществлялись посредством библиотеки Prophet [?].

Реализация Prophet представляет собой аддитивную регрессионную модель, которая разлагает временной ряд на следующие компоненты:

$$y(t) = g(t) + s(t) + h(t) + \varepsilon_t \quad (6)$$

где $g(t)$ — компонент тренда, $s(t)$ — компонент сезонности, $h(t)$ — компонент праздничных эффектов, а ε_t — случайная ошибка.

Компонент тренда $g(t)$ может быть представлен в виде логистического роста $g(t)_{log}$ или кусочно-линейного тренда с точками изменения $g(t)_{lin}$:

$$g(t)_{lin} = (k + \sum_{j=1}^S \delta_j)t + (m + \sum_{j=1}^S \gamma_j) \quad (\text{линейный тренд}) \quad (7)$$

$$g(t)_{log} = \frac{C(t)}{1 + \exp(-g(t)_{lin})} \quad (\text{нелинейный логистический рост}) \quad (8)$$

Сезонный компонент $s(t)$ моделируется с использованием ряда Фурье:

$$s(t) = \sum_{n=1}^N \left(a_n \cos\left(\frac{2\pi nt}{P}\right) + b_n \sin\left(\frac{2\pi nt}{P}\right) \right) \quad (9)$$

Праздничные эффекты $h(t)$ моделируются как сумма индикаторных функций для каждого праздника i :

$$h(t) = \sum_{i=1}^L \theta_i \mathbb{1}_{t \in D_i} \quad (10)$$

Оценка и оптимизация параметров модели $\hat{\theta}$ выполняется с использованием метода максимального правдоподобия:

$$\hat{\theta} = \arg \min_{\theta} (-\log p(y|\theta)) \left\{ = \frac{n}{2} \log(2\pi) + \frac{n}{2} \log(\sigma^2) + \frac{1}{2\sigma^2} \sum_t \left(y(t) - \sum_i f_i(t) \right)^2 \right\} \quad (11)$$

где θ — параметры модели, n — количество наблюдений, σ^2 — дисперсия ошибки, $y(t)$ — фактические значения, а $f_i(t)$ — компоненты модели.

Прогнозирование осуществляется путём экстраполяции тренда, использования сезонного компонента и учёта праздничных эффектов:

$$\hat{y}(t+h) = \hat{g}(t+h) + \hat{s}(t+h) + \hat{h}(t+h) \quad (12)$$

4.2 Проблемы и ограничения классического подхода

Декомпозиция словаря. Разобьём словарь на три непересекающиеся подмножества

$$\mathcal{W}_{\text{all}} = \mathcal{W}_{\text{core}} \cup \mathcal{W}_{\text{WN}} \cup \mathcal{W}_{\text{SD}}, \quad \mathcal{W}_a \cap \mathcal{W}_b = \emptyset, a \neq b.$$

1. Core слова. $\mathcal{W}_{\text{core}} = \{w \in \mathcal{W}_{\text{all}} \mid \rho_w := \text{Corr}(f(w, t), f(w, t+1)) \gg 0\}$. Для $w \in \mathcal{W}_{\text{core}}$ предполагается устойчивая положительная автокорреляция $\rho_w := \text{Corr}(f(w, t), f(w, t+1)) \gg 0$. Два остальных класса нарушают это свойство и вносят шум в агрегаты $f(T_k, t)$.

2. White-noise слова. $\mathcal{W}_{\text{WN}} = \{w \in \mathcal{W}_{\text{all}} \mid f(w, t) = [\varepsilon_w(t)]_+, \rho_w = 0\}$. Для $w \in \mathcal{W}_{\text{WN}}$ задаётся

$$f(w, t) = [\varepsilon_w(t)]_+, \quad \varepsilon_w(t) \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(\mu_{\text{WN}}, \sigma_{\text{WN}}^2),$$

где $[x]_+ = \max\{0, x\}$. Тогда $\rho_w = 0$, $\text{Var} f(w, t) = \sigma_{\text{WN}}^2$, а вклад таких слов в $\nu_k(t)$ представляет чистый гауссов шум.

3. Spike-decay слова. $\mathcal{W}_{\text{SD}} = \{w \in \mathcal{W}_{\text{all}} \mid f(w, t) = [S_w(t) + \varepsilon_w(t)]_+, \rho_w(\tau) \approx 0\}$, $\sum A_{w,m} \varkappa(t - \tau_{w,m})$, $\varkappa(\tau) = \frac{e^{-\lambda|\tau|}}{1 + \tau^2}$. Для $w \in \mathcal{W}_{\text{SD}}$

$$f(w, t) = [S_w(t) + \varepsilon_w(t)]_+, \quad S_w(t) = \sum_{m=1}^{M_w} A_{w,m} \varkappa(t - \tau_{w,m}), \quad \varkappa(\tau) = \frac{e^{-\lambda|\tau|}}{1 + \tau^2},$$

$\varepsilon_w(t) \sim \mathcal{N}(\mu_{\text{SD}}, \sigma_{\text{SD}}^2)$. Сигнал $S_w(t)$ создаёт редкие пики с экспоненциальным затуханием, $\rho_w(\tau) \approx 0$ для $|\tau| \geq 1$, но $\text{Var} f(w, t) \gg \text{Var} f(u, t)$ ($u \in \mathcal{W}_{\text{core}}$), что приводит к выбросам.

Воздействие на агрегаты. Для темы T_k представим $f(T_k, t) = f^{(\text{core})}(T_k, t) + f^{(\text{WN})}(T_k, t) + f^{(\text{SD})}(T_k, t)$, где компоненты соответствуют разбиению слов $\mathcal{W}_{\text{all}} = \mathcal{W}_{\text{core}} \cup \mathcal{W}_{\text{WN}} \cup \mathcal{W}_{\text{SD}}$. Введём обозначения: $\sigma_{\text{WN}}^2 := \text{Var}(f^{(\text{WN})}(T_k, t))$, $\sigma_{\text{SD}}^2 := \text{Var}(f^{(\text{SD})}(T_k, t))$.

Утверждение 1 (Задворнов, 2025) Пусть выполняется условие попарной некоррелированности: $\forall a \neq b, \forall \tau \in \mathbb{Z} : \text{Cov}(f^{(a)}(T_k, t), f^{(b)}(T_k, t + \tau)) = 0$. тогда:

1. Ковариация между $f(T_k, t)$ и $f(T_k, t + 1)$ определяется только ядром:

$$\text{Cov}(f(T_k, t), f(T_k, t + 1)) = \text{Cov}(f^{(\text{core})}(T_k, t), f^{(\text{core})}(T_k, t + 1)).$$

2. Дисперсия агрегата и лаг-1 автокорреляция выражаются как:

$$\text{Var } f(T_k, t) = \text{Var } f^{(\text{core})}(T_k, t) + \sigma_{\text{WN}}^2 + \sigma_{\text{SD}}^2,$$

$$\rho_k(1) = \frac{\text{Cov}^{(\text{core})}}{\text{Var } f^{(\text{core})}(T_k, t) + \sigma_{\text{WN}}^2 + \sigma_{\text{SD}}^2},$$

$$\text{где } \text{Cov}^{(\text{core})} = \text{Cov}(f^{(\text{core})}(T_k, t), f^{(\text{core})}(T_k, t + 1)).$$

Доказательство. Доказательство п.1: Распишем ковариацию, используя линейность и условие некоррелированности:

$$\begin{aligned} & \text{Cov}(f(T_k, t), f(T_k, t + 1)) \\ &= \sum_{a,b} \text{Cov}(f^{(a)}(t), f^{(b)}(t + 1)) \\ &= \sum_a \text{Cov}(f^{(a)}(t), f^{(a)}(t + 1)) \quad (\text{при } a \neq b \text{ ковариации нулевые}). \end{aligned}$$

Для $\mathcal{W}_{\text{WN}}$ по определению $\rho_w = 0$, откуда $\text{Cov}(f^{(\text{WN})}(t), f^{(\text{WN})}(t + 1)) = 0$. Для $\mathcal{W}_{\text{SD}}$ по условию $\rho_w(\tau) \approx 0$ при $\tau \neq 0$, следовательно, $\text{Cov}(f^{(\text{SD})}(t), f^{(\text{SD})}(t + 1)) \approx 0$.

Таким образом:

$$\text{Cov}(f(T_k, t), f(T_k, t + 1)) = \text{Cov}(f^{(\text{core})}(t), f^{(\text{core})}(t + 1)).$$

Доказательство п.2: Дисперсия суммы:

$$\begin{aligned}
 \text{Var } f(T_k, t) &= \text{Var} \left(\sum_a f^{(a)}(t) \right) \\
 &= \sum_a \text{Var}(f^{(a)}(t)) \quad (\text{ковариации между компонентами нулевые}) \\
 &= \text{Var } f^{(\text{core})}(t) + \sigma_{\text{WN}}^2 + \sigma_{\text{SD}}^2.
 \end{aligned}$$

Лаг-1 автокорреляция:

$$\rho_k(1) = \frac{\text{Cov}(f(t), f(t+1))}{\text{Var } f(t)} = \frac{\text{Cov}^{(\text{core})}}{\text{Var } f^{(\text{core})}(t) + \sigma_{\text{WN}}^2 + \sigma_{\text{SD}}^2}.$$

□

Из утверждения 1 непосредственно следует:

$$\rho_k(1) = \frac{\text{Cov}(f^{(\text{core})}(T_k, t), f^{(\text{core})}(T_k, t+1))}{\text{Var } f(T_k, t)} \leq \rho_k^{\text{core}} \frac{\text{Var } f^{(\text{core})}(T_k, t)}{\text{Var } f^{(\text{core})}(T_k, t) + \sigma_{\text{WN}}^2 + \sigma_{\text{SD}}^2},$$

где ρ_k^{core} – лаг-1 автокорреляция ядра.

Вывод для ARIMA-прогноза. Чем больше σ_{WN}^2 и σ_{SD}^2 , тем сильнее снижается $\rho_k(1)$, нарушая предпосылку AR-модели о существенной корреляционной зависимости, и тем сильнее размывается сигнал, что приводит к деградации AR-прогноза. Отсюда необходимость альтернативного подхода, который учитывает $\mathcal{W}_{\text{WN}} \cup \mathcal{W}_{\text{SD}}$ в прогностической модели.

4.3 Альтернативный корреляционный подход

Альтернативный подход заключается в рассмотрении вектора корреляций частот слов с собственными будущими значениями (реализация с помощью pls-регрессии) и выделении для прогноза тематики только слов с наибольшими корреляционными значениями. Далее для каждого слова w_k построить отдельную AR-модель, предсказывающую популярность (относительную долю) слова w_k среди выделенных слов $\mathcal{W}_{\text{sel}}$ в момент t . Относительная доля считается как количество упоминаний слова за период, поделённое на количество упоминаний выделенных слов за период. Далее суммировать и нормировать прогнозы слов, чтобы в итоге получить популярность тематики как сумму популярностей слов внутри неё.

Корреляционный скрининг. Для каждого $w \in \mathcal{W}_{\text{all}}$ вычисляется лаг-1 выборочная автокорреляция

$$\hat{\rho}_w := \text{Corr}(f(w, t), f(w, t + 1)), \quad t \in T_{\text{train}},$$

Определим индикатор

$$\theta_w := \mathbb{I}[\hat{\rho}_w \geq r], \quad r \in (0, 1), \quad \bar{\theta} \in \{0, 1\}^W,$$

и подсловарь выделенных слов $\mathcal{W}_{\text{sel}} = \{w : \theta_w = 1\}$.

Нормированные ряды слов.

$$s(w, t) := \frac{f(w, t)}{\sum_{v \in \mathcal{W}_{\text{sel}}} f(v, t)}, \quad t \in \{0, \dots, T-1\}, w \in \mathcal{W}_{\text{sel}}.$$

Прогноз слова. Для каждого $w \in \mathcal{W}_{\text{sel}}$ строится скалярная AR-модель

$$\hat{s}(w, t + 1 \mid \psi_w) = g_{\psi_w}(s(w, t), \dots, s(w, t - t_0 + 1)),$$

где $\psi_w \in \mathbb{R}^{d_w}$ — параметры, оценённые на T_{train} методом МНК.

Согласованная нормировка.

$$\tilde{s}(w, t+1) := \frac{\hat{s}(w, t+1 \mid \psi_w)}{\sum_{v \in \mathcal{W}_{\text{sel}}} \hat{s}(v, t+1 \mid \psi_v)}, \quad \sum_{w \in \mathcal{W}_{\text{sel}}} \tilde{s}(w, t+1) = 1.$$

Агрегация по темам.

$$\hat{\nu}_k(t+1) = \sum_{w \in T_k} \theta_w \tilde{s}(w, t+1), \quad \hat{\nu}(t+1) \in \Delta^K.$$

Таким образом $\mathcal{W}_{\text{WN}} \cup \mathcal{W}_{\text{SD}}$ автоматически исключаются при $\hat{\rho}_w < r$, а прогноз строится только на информативном подмножестве $\mathcal{W}_{\text{sel}}$.

Оптимизационная постановка. Разделив параметры на $\bar{\varphi} = (\bar{\theta}, \bar{\psi})$, $\bar{\psi} = (\psi_w)_{w:\theta_w=1}$, получаем задачу

$$\min_{\bar{\theta}, \bar{\psi}} \frac{1}{|T_{\text{test}}|} \sum_{t \in T_{\text{test}}} \|\bar{\nu}(t) - \hat{\nu}(t \mid \bar{\theta}, \bar{\psi}, t-1:t-t_0)\|_2^2, \quad \text{s.t. } \theta_w = 0 \quad \forall w : \hat{\rho}_w < r.$$

Теорема (Задворнов, 2025) Пусть для темы c :

- $\mu_c = \mathbb{E}[Y_c(T-1) \mid \mathcal{F}_{T-2}]$ - условное матожидание агрегата по всем словам
- $\mu_c^{(\text{core})} = \mathbb{E}[\hat{Y}_c^{(\text{core})}(T-1) \mid \mathcal{F}_{T-2}]$ - условное матожидание агрегата по core-словам
- Выполнены условия Утверждения 1 о разбиении словаря

и дополнительно выполнены условия на шумовые слова:

1. Для $w \in \mathcal{W}_{\text{WN}}$: $\mathbb{E}[f(w, T-1) \mid \mathcal{F}_{T-2}] \leq C_{\text{WN}} \sigma_{\text{WN}}$ где $C_{\text{WN}} = \frac{1}{\sqrt{2\pi}}$
2. Для $w \in \mathcal{W}_{\text{SD}}$: $\mathbb{E}[f(w, T-1) \mid \mathcal{F}_{T-2}] \leq C_{\text{SD}} \sigma_{\text{SD}}$ (в отсутствие пиков)
3. $|\mathcal{W}_{\text{WN}}| C_{\text{WN}}^2 + |\mathcal{W}_{\text{SD}}| C_{\text{SD}}^2 < \varkappa$

где $\varkappa > 0$ - минимальное собственное значение информационной матрицы модели прогноза.

Тогда:

$$\text{MSE}(\hat{Y}_c^{(\text{core})}(T-1)) < \text{MSE}(\hat{Y}_c^{(\text{all})}(T-1)).$$

Доказательство. Шаг 1: Ошибки прогнозов

$$Y_c(T-1) = \mu_c + \varepsilon_c, \quad \mathbb{E}[\varepsilon_c \mid \mathcal{F}_{T-2}] = 0, \quad \text{Var}(\varepsilon_c \mid \mathcal{F}_{T-2}) = \sigma_c^2.$$

Из условия несмещенности для полного прогноза:

$$\mathbb{E}[\hat{Y}_c^{(\text{all})}(T-1) \mid \mathcal{F}_{T-2}] = \mu_c$$

Для прогноза по стабильным словам:

$$\mathbb{E}[\hat{Y}_c^{(\text{core})}(T-1) \mid \mathcal{F}_{T-2}] = \mu_c^{(\text{core})} = \sum_{w \in \mathcal{S}_c^{\text{core}}} \mathbb{E}[X_w(T-1) \mid \mathcal{F}_{T-2}]$$

Заметим, что в общем случае $\mu_c^{(\text{core})} \neq \mu_c$, но нам это не важно для дисперсии.

Ошибки прогнозов:

$$e^{(\text{all})} = Y_c(T-1) - \hat{Y}_c^{(\text{all})}(T-1) = \varepsilon_c + (\mu_c - \hat{Y}_c^{(\text{all})}(T-1))$$

$$e^{(\text{core})} = Y_c(T-1) - \hat{Y}_c^{(\text{core})}(T-1) = \varepsilon_c + (\mu_c - \hat{Y}_c^{(\text{core})}(T-1))$$

Тогда условное MSE:

$$\mathbb{E}[(e^{(\text{all})})^2 \mid \mathcal{F}_{T-2}] = \mathbb{E}[\varepsilon_c^2 \mid \mathcal{F}_{T-2}] + \mathbb{E}[(\mu_c - \hat{Y}_c^{(\text{all})}(T-1))^2 \mid \mathcal{F}_{T-2}] + 2\mathbb{E}[\varepsilon_c(\mu_c - \hat{Y}_c^{(\text{all})}(T-1)) \mid \mathcal{F}_{T-2}]$$

Поскольку ε_c не зависит от $\hat{Y}_c^{(\text{all})}(T-1)$ (который строится по истории до $T-2$) и $\mathbb{E}[\varepsilon_c \mid \mathcal{F}_{T-2}] = 0$, то ковариационное слагаемое равно 0.

$$= \sigma_c^2 + \text{Var}(\hat{Y}_c^{(\text{all})}(T-1) \mid \mathcal{F}_{T-2})$$

Аналогично:

$$\mathbb{E}[(e^{(\text{core})})^2 \mid \mathcal{F}_{T-2}] = \sigma_c^2 + \text{Var}(\hat{Y}_c^{(\text{core})}(T-1) \mid \mathcal{F}_{T-2}) + (\mu_c - \mu_c^{(\text{core})})^2$$

Потому что:

$$e^{(\text{core})} = \varepsilon_c + (\mu_c - \widehat{Y}_c^{(\text{core})}(T-1)) = \varepsilon_c + (\mu_c - \mu_c^{(\text{core})}) + (\mu_c^{(\text{core})} - \widehat{Y}_c^{(\text{core})}(T-1))$$

Тогда:

$$\begin{aligned} \mathbb{E}[(e^{(\text{core})})^2 \mid \mathcal{F}_{T-2}] &= \mathbb{E}[\varepsilon_c^2] + (\mu_c - \mu_c^{(\text{core})})^2 + \mathbb{E}[(\mu_c^{(\text{core})} - \widehat{Y}_c^{(\text{core})}(T-1))^2] \\ &+ 2\mathbb{E}[\varepsilon_c(\mu_c - \mu_c^{(\text{core})})] + 2\mathbb{E}[\varepsilon_c(\mu_c^{(\text{core})} - \widehat{Y}_c^{(\text{core})}(T-1))] + 2(\mu_c - \mu_c^{(\text{core})})\mathbb{E}[\mu_c^{(\text{core})} - \widehat{Y}_c^{(\text{core})}(T-1)] \end{aligned}$$

Заметим:

$$\mathbb{E}[\varepsilon_c(\mu_c - \mu_c^{(\text{core})}) \mid \mathcal{F}_{T-2}] = (\mu_c - \mu_c^{(\text{core})})\mathbb{E}[\varepsilon_c \mid \mathcal{F}_{T-2}] = 0$$

$$\mathbb{E}[\varepsilon_c(\mu_c^{(\text{core})} - \widehat{Y}_c^{(\text{core})}(T-1)) \mid \mathcal{F}_{T-2}] = \mathbb{E}[\varepsilon_c \mid \mathcal{F}_{T-2}] \cdot (\mu_c^{(\text{core})} - \mathbb{E}[\widehat{Y}_c^{(\text{core})}(T-1) \mid \mathcal{F}_{T-2}]) = 0$$

$\mathbb{E}[\mu_c^{(\text{core})} - \widehat{Y}_c^{(\text{core})}(T-1) \mid \mathcal{F}_{T-2}] = 0$ (по условиям из утверждения 1, примененному к каждому слову и агрегированию)

Поэтому:

$$\mathbb{E}[(e^{(\text{core})})^2 \mid \mathcal{F}_{T-2}] = \sigma_c^2 + (\mu_c - \mu_c^{(\text{core})})^2 + \text{Var}(\widehat{Y}_c^{(\text{core})}(T-1) \mid \mathcal{F}_{T-2})$$

Итог условное MSE:

$$\text{MSE}^{(\text{all})} = \mathbb{E} \left[\left(e^{(\text{all})} \right)^2 \mid \mathcal{F}_{T-2} \right] = \sigma_c^2 + \text{Var} \left(\widehat{Y}_c^{(\text{all})}(T-1) \mid \mathcal{F}_{T-2} \right)$$

$$\text{MSE}^{(\text{core})} = \mathbb{E} \left[\left(e^{(\text{core})} \right)^2 \mid \mathcal{F}_{T-2} \right] = \sigma_c^2 + \text{Var} \left(\widehat{Y}_c^{(\text{core})}(T-1) \mid \mathcal{F}_{T-2} \right) + B^2$$

где $B = \mu_c - \mu_c^{(\text{core})}$, $\sigma_c^2 = \text{Var}(Y_c(T-1) \mid \mathcal{F}_{T-2})$.

Шаг 2: Выражение смещения Смещение B равно сумме вкладов шумовых слов:

$$B = \sum_{w \in \mathcal{W}_{\text{WN}}} \mathbb{E}[f(w, T-1) \mid \mathcal{F}_{T-2}] + \sum_{w \in \mathcal{W}_{\text{SD}}} \mathbb{E}[f(w, T-1) \mid \mathcal{F}_{T-2}]$$

Используя условия 1 и 2:

$$|B| \leq \sum_{w \in \mathcal{W}_{\text{WN}}} C_{\text{WN}} \sigma_{\text{WN}} + \sum_{w \in \mathcal{W}_{\text{SD}}} C_{\text{SD}} \sigma_{\text{SD}}$$

$$B^2 \leq \left(\sum_{w \in \mathcal{W}_{\text{WN}}} C_{\text{WN}} \sigma_{\text{WN}} + \sum_{w \in \mathcal{W}_{\text{SD}}} C_{\text{SD}} \sigma_{\text{SD}} \right)^2 \leq 2 (|\mathcal{W}_{\text{WN}}|^2 C_{\text{WN}}^2 \sigma_{\text{WN}}^2 + |\mathcal{W}_{\text{SD}}|^2 C_{\text{SD}}^2 \sigma_{\text{SD}}^2)$$

Шаг 3: Разность дисперсий прогнозов Из Утверждения 1 и свойств моделей ARIMA/Prophet:

$$\Delta V := \text{Var} \left(\hat{Y}_c^{(\text{all})}(T-1) \mid \mathcal{F}_{T-2} \right) - \text{Var} \left(\hat{Y}_c^{(\text{core})}(T-1) \mid \mathcal{F}_{T-2} \right) \geq \kappa (\sigma_{\text{WN}}^2 |\mathcal{W}_{\text{WN}}| + \sigma_{\text{SD}}^2 |\mathcal{W}_{\text{SD}}|)$$

Шаг 4: Сравнение B^2 и ΔV Покажем, что $B^2 < \Delta V$:

$$2 (|\mathcal{W}_{\text{WN}}|^2 C_{\text{WN}}^2 \sigma_{\text{WN}}^2 + |\mathcal{W}_{\text{SD}}|^2 C_{\text{SD}}^2 \sigma_{\text{SD}}^2) < \kappa (\sigma_{\text{WN}}^2 |\mathcal{W}_{\text{WN}}| + \sigma_{\text{SD}}^2 |\mathcal{W}_{\text{SD}}|)$$

Разделим обе части на $\sigma_{\text{WN}}^2 |\mathcal{W}_{\text{WN}}| + \sigma_{\text{SD}}^2 |\mathcal{W}_{\text{SD}}|$:

$$2 \left(\frac{|\mathcal{W}_{\text{WN}}|^2 C_{\text{WN}}^2 \sigma_{\text{WN}}^2}{\sigma_{\text{WN}}^2 |\mathcal{W}_{\text{WN}}| + \sigma_{\text{SD}}^2 |\mathcal{W}_{\text{SD}}|} + \frac{|\mathcal{W}_{\text{SD}}|^2 C_{\text{SD}}^2 \sigma_{\text{SD}}^2}{\sigma_{\text{WN}}^2 |\mathcal{W}_{\text{WN}}| + \sigma_{\text{SD}}^2 |\mathcal{W}_{\text{SD}}|} \right) < \kappa$$

Усилим левую часть:

$$\frac{|\mathcal{W}_{\text{WN}}|^2 C_{\text{WN}}^2 \sigma_{\text{WN}}^2}{\sigma_{\text{WN}}^2 |\mathcal{W}_{\text{WN}}|} + \frac{|\mathcal{W}_{\text{SD}}|^2 C_{\text{SD}}^2 \sigma_{\text{SD}}^2}{\sigma_{\text{SD}}^2 |\mathcal{W}_{\text{SD}}|} = |\mathcal{W}_{\text{WN}}| C_{\text{WN}}^2 + |\mathcal{W}_{\text{SD}}| C_{\text{SD}}^2 < \kappa$$

что выполнено по условию 3.

Шаг 5: Итоговое неравенство для MSE Из $B^2 < \Delta V$ следует:

$$\begin{aligned} \text{MSE}^{(\text{core})} &= \sigma_c^2 + \text{Var} \left(\hat{Y}_c^{(\text{core})}(T-1) \mid \mathcal{F}_{T-2} \right) + B^2 < \sigma_c^2 + \text{Var} \left(\hat{Y}_c^{(\text{core})}(T-1) \mid \mathcal{F}_{T-2} \right) + \Delta V \\ &= \sigma_c^2 + \text{Var} \left(\hat{Y}_c^{(\text{all})}(T-1) \mid \mathcal{F}_{T-2} \right) = \text{MSE}^{(\text{all})} \end{aligned}$$

Таким образом, $\text{MSE}^{(\text{core})} < \text{MSE}^{(\text{all})}$. □

5 Модифицированная постановка задачи

Параметры.

$$\bar{\theta} := (\theta_w)_{w \in \mathcal{W}_{\text{all}}} \in \{0,1\}^W, \quad \bar{\psi} := (\psi_w)_{w: \theta_w=1} \in \mathbb{R}^d,$$

где θ_w — индикатор отбора слова, ψ_w — вектор коэффициентов скалярной AR-модели g_{ψ_w} , определённой в §4.3.

Предсказание.

$$\hat{\nu}_k(t \mid \bar{\theta}, \bar{\psi}) := \frac{\sum_{w \in T_k} \theta_w \hat{s}(w, t \mid \psi_w)}{\sum_{w' \in W_{\text{all}}} \theta_{w'} \hat{s}(w', t \mid \psi_{w'})}, \quad \hat{\nu}(t \mid \bar{\theta}, \bar{\psi}) \in \Delta^K.$$

Оптимизационная задача. Тогда исходная задача минимизации модифицируется, и представима в виде:

$$\begin{aligned} & \min_{\bar{\varphi} \in \mathbb{R}^d} \frac{1}{|T_{\text{test}}|} \sum_{t \in T_{\text{test}}} \left\| \bar{\nu}(t) - \hat{\nu}(t \mid \bar{\varphi}, t-1 : t-t_0) \right\|_2^2 \\ & = \\ & \min_{\bar{\theta} \in [0,1]^W, \bar{\psi} \in \mathbb{R}^d} \frac{1}{|T_{\text{test}}|} \sum_{t \in T_{\text{test}}} \left\| \bar{\nu}(t) - \hat{\nu}(t \mid \bar{\psi}, \bar{\theta}, t-1 : t-t_0) \right\|_2^2 \\ & \text{s.t. } \Theta_w = 0, \quad \forall T_k \in \bar{T}, \forall w \in T_k : \text{Corr}(f(w, t), f(T_k, t+1)) < r. \\ & \hspace{25em} (\mathcal{P}_{\text{corr}}) \end{aligned}$$

Связь с классической схемой. При $\theta_w \equiv 1$ задача $(\mathcal{P}_{\text{corr}})$ редуцируется к исходной постановке (?). Таким образом:

$$\underbrace{\bar{\theta}}_{\text{фильтр слов}} + \underbrace{\bar{\psi}}_{\text{параметры AR}} \implies \hat{\nu}(t),$$

что одновременно устраняет шум $\mathcal{W}_{\text{WN}} \cup \mathcal{W}_{\text{SD}}$ и сохраняет авторегрессионную динамику.

5.1 Псевдокод алгоритма

Тогда предложенный алгоритм ARFilter представим в виде Алгоритм 1.

Algorithm 1 ARFilter

Require: Корпус $\mathcal{D} = \{(d_i, t_i)\}_{i=1}^N$, порог r , окно t_0

Ensure: $\bar{T}, \bar{\theta}, \bar{\psi}$

- 1: Извлечь $\mathcal{W}_{\text{all}}$ и частоты $f(w, t)$ по $\mathcal{D}$
 - 2: Построить разбиение $\bar{T} = \{T_k\}$ с помощью вероятностной модели (например, LDA/Embeddings+KMeans)
 - 3: for all $w \in \mathcal{W}_{\text{all}}$ do
 - 4: $\hat{\rho}_w \leftarrow \text{Corr}(f(w, t), f(w, t + 1))$
 - 5: $\Theta_w \leftarrow \mathbb{I}[\hat{\rho}_w \geq r]$
 - 6: end for
 - 7: $\mathcal{W}_{\text{sel}} \leftarrow \{w : \Theta_w = 1\}$
 - 8: for all $w \in \mathcal{W}_{\text{sel}}$ do
 - 9: $s(w, t) \leftarrow \frac{f(w, t)}{\sum_{v \in \mathcal{W}_{\text{sel}}} f(v, t)}$
 - 10: $\psi_w \leftarrow \arg \min_{\psi} \sum_{t \in T_{\text{train}}} (s(w, t) - g_{\psi}(s(w, t - 1 : t - t_0)))^2$
 - 11: end for
 - 12: return $\bar{T}, \bar{\theta}, \bar{\psi}$
-

6 Вычислительный эксперимент. Синтетический генератор и статистические свойства данных

Цель. Проверить гипотезу $\mathbb{E}[\mathcal{L}_{\text{corr}}] < \mathbb{E}[\mathcal{L}_{\text{base}}]$, где $\mathcal{L}$ — функционал ошибки (??), для синтетического корпуса с шумовыми словами.

Код. Код для данного эксперимента доступен по адресу: <https://github.com/LoveMyWork/2024-Project-167/tree/master/src>

6.1 Генерация данных

Рассматриваются $K = 3$ кластера $\bar{T} = \{\text{Sports, Music, Tech}\}$, каждый содержит W_{core} core-слов, W_{WN} white-noise слов и W_{SD} spike-decay слов ($W = W_{\text{core}} + W_{\text{WN}} + W_{\text{SD}}$).

1. Core-слова Для фиксированного кластера c каждое core-слово $j = 1, 2, 3$ генерируется по формуле

$$s_{c,j}(t) = \underbrace{(\text{base_level} + \text{trend_step} \cdot t)}_{\text{линейный тренд}} + \underbrace{\text{amp_core} \cdot \sin\left(\frac{2\pi t}{p_j}\right)}_{\text{синусоидальный вклад}}, \quad t = 0, 1, \dots, T-$$

Добавляется гауссов шум $\varepsilon_{c,j}^{(\text{core})}(t) \sim \mathcal{N}(0, \sigma_{\text{core}}^2)$ и итоговый неотрицательный ряд:

$$X_{c,j}(t) = \max\left\{0, s_{c,j}(t) + \varepsilon_{c,j}^{(\text{core})}(t)\right\}.$$

Для $j = 4$ вместо синусоиды используется чистый линейный тренд:

$$X_{c,4}(t) = \max\left\{0, \text{base_level} + \text{trend_step} t + \varepsilon_{c,4}^{(\text{core})}(t)\right\}.$$

2. White-noise слова Для $j = 5, \dots, 4 + W_{\text{WN}}$ (white-noise) генерируется:

$$X_{c,j}^{(\text{WN})}(t) = \max\left\{0, \mathcal{N}(\mu_{\text{WN}}, \sigma_{\text{WN}}^2)\right\}, \quad \mu_{\text{WN}} = 5, \sigma_{\text{WN}} = 6.0.$$

Таким образом, каждое WN-слово — это чистый гауссов шум со сдвигом 5 и дисперсией 36, практически некоррелированный с core-словами.

3. Spike-decay слова Для $j = 5 + W_{\text{WN}}, \dots, 4 + W_{\text{WN}} + W_{\text{SD}}$ (Spike-Decay) задаётся

$$X_{c,j}^{(\text{SD})}(t) = \max\left\{0, S_{c,j}(t) + \delta_{c,j}(t)\right\},$$

где

- $\delta_{c,j}(t) \sim \mathcal{N}(\mu_{\text{SD}}, \sigma_{\text{WN}}^2)$, $\mu_{\text{SD}} = 5$, $\sigma_{\text{WN}} = 6.0$.
- $S_{c,j}(t) = \sum_{m=1}^M \frac{A_m}{1 + (t - \tau_m)^2} \exp(-\lambda(t - \tau_m))$ — сумма M гиперболических пиков (центры $\tau_m \in \{0, \dots, T - 1\}$, амплитуды $A_m \sim \text{Uniform}(10, 30)$), затухающая с коэффициентом $\lambda > 0$.

В результате SD-слова содержат резкие локальные выбросы и экспоненциальное затухание, что создаёт «прерывистость» в суммарном ряде.

Суммарный ряд кластера Наконец, для каждого кластера c определяется агрегированный ряд

$$Y_c(t) = \sum_{j=1}^4 X_{c,j}^{(\text{core})}(t) + \sum_{j=5}^{4+W_{\text{WN}}} X_{c,j}^{(\text{WN})}(t) + \sum_{j=5+W_{\text{WN}}}^{4+W_{\text{WN}}+W_{\text{SD}}} X_{c,j}^{(\text{SD})}(t), \quad t = 0, \dots, T-1.$$

Параметры

- В проведённом эксперименте каждый кластер содержит $W = 20$ «слов».
- Число core слов: $W_{\text{core}} = 4$.
- Число white-noise слов: $W_{\text{WN}} = 8$.
- Число spike-decay слов: $W_{\text{SD}} = 8$.
- Временной ряд имеет длину $T = 40$ точек (каждая точка — двухнедельный интервал), то есть 40 наблюдений за 80 недель.
- Базовый уровень (линейный тренд):

$$\text{base_level} = 220, \quad \text{trend_step} = 7.2.$$

- Амплитуда синусоид для core-слов: $\text{amp_core} = 20$.
- Дисперсии шумов:

$$\sigma_{\text{core}} = 0.4, \quad \sigma_{\text{WN}} = 6.0.$$

- Для трёх core-слов внутри каждого кластера задаются периоды $\{p_1, p_2, p_3\} = \{5, 6, 12\}$ (в двухнедельных точках).

По построению:

- $\rho(X_{c,k}^{(\text{core})}, Y_c) \approx 0.8\text{--}0.95$ (высокая корреляция),
- $\rho(X_{c,j}^{(\text{WN})}, Y_c) \approx 0, \rho(X_{c,j}^{(\text{SD})}, Y_c) \approx 0$ (шум мало коррелирован с сигналом),
- $\text{Var}(Y_c) \approx \underbrace{\sum_{j=1}^4 \text{Var}(X_{c,j}^{(\text{core})})}_{\approx 4 \cdot 0.16} + \underbrace{W_{\text{WN}} \cdot 36}_{288} + \underbrace{\text{pike-variance}}_{\gg 36} \approx$
большое значение.

Следовательно, шумовая часть (16 слов) доминирует по дисперсии над core-словами, что усложняет прямой Prophet-прогноз агрегата, но не влияет на прогноз «слово по слову» (Предложенный подход) после отбора core-слов.

6.2 Методы

1. Классический подход: прямой прогноз агрегата $Y_c(t+1)$, построенный по ряду $\{Y_c(0), \dots, Y_c(T-2)\}$. Используется $\text{ARIMA}(p_k, d_k, q_k)$, (p_k, d_k, q_k) выбирается по AIC.
2. Предложенный подход: алгоритм §5.1 с порогом r (скрининг + локальные AR + агрегация).
 - вычисляем «важности» слов $w \in \mathcal{W}_c$ через PLS-регрессию между признаками $\{X_w(t)\}$ и целевыми $\{X_w(t+1)\}$;
 - отбираем подмножество $\mathcal{S}_c \subset \mathcal{W}_c$ (core-слова) с наибольшими PLS-коэффициентами;

- строим Prophet-прогнозы $\hat{X}_w(T-1)$ для каждого $w \in \mathcal{S}_c$;
- суммируем их, получая $\hat{Y}_c^{(wl)}(T-1) = \sum_{w \in \mathcal{S}_c} \hat{X}_w(T-1)$.

Условия. Разобьём все точки на train ($t = 0, \dots, T-2$) и test ($t = T-1$). Далее описаны формулы.

6.3 Описание хода эксперимента

Шаг 1: PLS-отбор «важных» слов (core-слов). На этапе train ($t = 0, \dots, T-2$) для каждой темы c формируем:

$$\mathbf{X}_c = \begin{pmatrix} X_{w_1}(0) & X_{w_2}(0) & \cdots & X_{w_{W_c}}(0) \\ X_{w_1}(1) & X_{w_2}(1) & \cdots & X_{w_{W_c}}(1) \\ \vdots & \vdots & \ddots & \vdots \\ X_{w_1}(T-2) & X_{w_2}(T-2) & \cdots & X_{w_{W_c}}(T-2) \end{pmatrix} \in \mathbb{R}^{(T-1) \times W_c},$$

$$\mathbf{Y}_c = \begin{pmatrix} X_{w_1}(1) & X_{w_2}(1) & \cdots & X_{w_{W_c}}(1) \\ X_{w_1}(2) & X_{w_2}(2) & \cdots & X_{w_{W_c}}(2) \\ \vdots & \vdots & \ddots & \vdots \\ X_{w_1}(T-1) & X_{w_2}(T-1) & \cdots & X_{w_{W_c}}(T-1) \end{pmatrix} \in \mathbb{R}^{(T-1) \times W_c}.$$

Здесь $X_{w_j}(t)$ — частота слова $w_j \in \mathcal{W}_c$ в момент t . Применяем PLS:

$$\text{PLS}(\mathbf{X}_c, \mathbf{Y}_c) \longrightarrow \mathbf{C}_c \in \mathbb{R}^{W_c \times W_c},$$

где $\mathbf{C}_c[j, k]$ — коэффициент при входном слове w_j и целевом w_k . Определим скалярную важность:

$$\text{imp}_c(w_j) = \sum_{k=1}^{W_c} |\mathbf{C}_c[j, k]|, \quad j = 1, \dots, W_c.$$

Большая $\text{imp}_c(w_j)$ означает, что слово w_j существенно помогает предсказывать все $\{X_{w_k}(t+1)\}$.

Шаг 2: Отбор core-слов. Задаём пороговый критерий (например, $\text{top-}p\%$) или фиксированное число K_c :

$$\mathcal{S}_c = \{ w \in \mathcal{W}_c : \text{imp}_c(w) - \text{в топ-}K_c \}, \quad |\mathcal{S}_c| = K_c \ll W_c.$$

$\mathcal{S}_c$ — набор core-слов, чьи значения $X_w(t)$ лучше всего прогнозируют $X_w(t+1)$.

Шаг 3: Классический подход — прогноз агрегата.

- Составляем тренировочный ряд $\{(t, Y_c(t))\}_{t=0}^{T-2}$, где $Y_c(t) = \sum_{w \in \mathcal{W}_c} X_w(t)$.
- Строим модель Prophet по этим $T-1$ точкам и получаем прогноз $\hat{Y}_c^{(\text{dir})}(T-1)$.

Шаг 4: Предложенный подход — прогноз core-слов.

- Для каждого $w \in \mathcal{S}_c$ строим Prophet на ряде $\{(t, X_w(t))\}_{t=0}^{T-2}$, получаем $\hat{X}_w(T-1)$.
- Суммируем эти прогнозы:

$$\hat{Y}_c^{(\text{wl})}(T-1) = \sum_{w \in \mathcal{S}_c} \hat{X}_w(T-1).$$

- Слова из $\mathcal{W}_c \setminus \mathcal{S}_c$ в предложенном подходе не участвуют.

Шаг 5: Оценка качества прогнозов. Истинное значение $Y_c(T-1)$ известно. Определим среднеквадратическую ошибку по всем C кластерам:

$$\text{MSE}_{\text{dir}} = \frac{1}{C} \sum_{c=1}^C \left(Y_c(T-1) - \hat{Y}_c^{(\text{dir})}(T-1) \right)^2,$$

$$\text{MSE}_{\text{wl}} = \frac{1}{C} \sum_{c=1}^C \left(Y_c(T-1) - \hat{Y}_c^{(\text{wl})}(T-1) \right)^2.$$

6.4 Результаты эксперимента

6.4.1 Сводка по построению тематических кластеров

Результаты кластеризации представлены в таблице 1. В соответствии с критериями, описанными в разделе «Кластеризация тем», был выбран алгоритм «Embedding + К-средних», так как он показывает метрики, лишь немного уступающие LDA (на 0.06), но значительно превосходит его по другим показателям.

Модель	Средняя когерентность	Когерентность
К-средних	0.63	0.69
LDA	0.693	0.71

Таблица 1 – Полученные метрики каждого алгоритма. Ошибка рассчитана по формуле «ошибка среднего значения».

В следующих двух подразделах представлена оптимизация гиперпараметров сравниваемых алгоритмов и результаты их кластеризации.

6.4.2 Embeddings + К-средних

Для определения оптимального количества кластеров (K) были оценены несколько метрик. В частности, использовался показатель средней когерентности, который количественно оценивает интерпретируемость кластеров для человека путём измерения семантического сходства между наиболее значимыми словами в кластере. Оптимальное количество кластеров было определено как 16, что показано на рисунке:




Рис. 1 – Зависимость когерентности от количества кластеров для алгоритма Embeddings + К-средних.

Полученная кластеризация с экспертной интерпретацией представлена в таблице 2. Среднее значение когерентности для 16 кластеров составило 0,63.

Кластер	Интерпретация	C_{cv}
0	НФЛ (американский футбол)	0.63
1	Футбол	0.43
2	Мотивационные хэштеги	0.75
3	Спортивные личности	0.58
4	Развлечения	0.58
5	Музыка	0.55
6	Политика и праздники	0.73
7	UFC	0.74
8	Эмоциональные хэштеги	0.70
9	Хэштеги социальных событий	0.73
10	Политические фигуры и события	0.59
11	Баскетбол	0.37
12	Знаменитости и публичные личности	0.65
13	Бизнес	0.65
14	Мировые события и страны	0.71
15	Развлечения	0.68
Среднее	—	0.63

Таблица 2 – Результаты кластеризации с использованием Embeddings + К-средних

Подход Embeddings + К-средних продемонстрировал хорошую тематическую когерентность внутри кластеров, что позволило провести содержательную интерпретацию и последующее прогнозирование. Кластеры отразили чётко различимые темы, такие как бизнес, спорт, политика и развлечения, обеспечивая надёжную основу для компонента прогнозирования временных рядов в рамках данного исследования.

Примеры, ссылки на алгоритмы, изображения кластеризации и другие детали, касающиеся метода Embeddings + К-средних, приведены в приложении.

6.4.3 Latent Dirichlet Allocation (LDA) для тем

Для устранения ограничений подхода на основе эмбедингов мы исследовали тематическое моделирование с использованием метода латентного размещения Дирихле (LDA) [3] напрямую на представлениях тем. Это позволило выявить скрытые тематические структуры в данных.

Согласно графику, зависимости качества кластеризации LDA от количества кластеров не наблюдается. Поэтому, для более корректного сравнения, было выбрано 16 кластеров, и рассчитаны метрики когерентности (см. таблицу).




Рис. 2 – Средняя когерентность в зависимости от количества кластеров

Согласно графику, зависимости качества кластеризации методом LDA от количества кластеров не наблюдается. Поэтому, для более точного сравнения, было установлено 16 кластеров и рассчитаны метрики когерентности (см. таблицу 3).

Кластер	C_{cv}
0	0.69
1	0.71
2	0.68
3	0.67
4	0.70
5	0.71
6	0.67
7	0.71
8	0.69
9	0.68
10	0.68
11	0.72
12	0.71
13	0.71
14	0.69
15	0.67
Среднее -	0.69

Таблица 3 – Результаты кластеризации с использованием LDA

В следующем разделе мы применим модель прогнозирования к кластерам, полученным в результате применения метода Embeddings + К-средних.

6.4.4 Сводка по прогнозированию будущих частот

Method	MSE_{Sports}	MSE_{Music}	MSE_{Tech}	MSE_{Avg}
Классический подход (Baseline)	0.041	0.013	0.016	0.023
Предложенный подход	0.001	0.003	0.003	0.002

Таблица 4 – Сравнение MSE для различных тем и методов




Рис. 3 – Визуальная проверка гипотезы. Четыре панели иллюстрируют статистические свойства синтетического кластера Sports.

А. Матрица Пирсоновских корреляций $\rho(f(w,t), f(u,t))$ для core-, WN- и SD-слов вместе с агрегатом $f(T_{\text{Sports}}, t)$ (см. определение f в (?)). Яркие красные клетки в блоке core-core и core-cluster показывают высокую взаимную корреляцию, тогда как блоки, связанные с WN/SD, близки к нулю. Следствие: наличие низкоррелированных WN/SD-слов подтверждает необходимость фильтрации.

В. Траектория доли темы $\nu_{\text{Sports}}(t)$ при учёте всех слов (синяя линия) и только core-слов (оранжевая, определена аналогично, но сумма по $\mathcal{W}_{\text{core}}$). Удаление шума делает ряд более гладким и уменьшает дисперсию. Следствие: шумовые слова искажают истинную динамику темы, что объясняет рост ошибки прямого прогноза.

С. Средняя абсолютная ошибка $\text{MAE} = |T_{\text{test}}|^{-1} \sum_{t \in T_{\text{test}}} |\hat{\nu}(t) - \nu(t)|$ для прогноз агрегата (классического подхода) и для суммы индивидуальных прогнозов отобранных слов (Предложенный подход). Ошибка после фильтрации в 20 раз меньше. Следствие: скрининг + локальный прогноз превосходят прямой метод.

D. Топ-15 абсолютных PLS-коэффициентов $|\beta_w|$ из модели, обученной на парах $\{f(w, t), f(w, t + 1)\}$. Core-слова (зелёный) доминируют, шумовые (серый) близки к нулю. Следствие: PLS корректно выделяет информативные признаки, подтверждая механизм фильтра.

6.5 Выводы

- MSE для классического подхода: $\text{MSE}_{\text{base}} = 0.023$.
- MSE для предложенного метода: $\text{MSE}_{\text{prop}} = 0.002$.
- Результат: $\text{MSE}_{\text{prop}} < \text{MSE}_{\text{base}}$.

Из табл. 4 следует, что среднеквадратичная ошибка прогноза при использовании предложенного корреляционного фильтра значительно ниже, чем у базового метода. Это подтверждает гипотезу о том, что исключение нерелевантных (white-noise и spike-decay) слов позволяет существенно повысить точность тематического прогноза.

7 Выносятся на защиту

1. Метод прогнозирования тематик во времени с использованием регуляризации при условии высокой волатильности

Метод основан на оптимизации (??) с двухкомпонентным вектором параметров $\bar{\varphi} = (\bar{\theta}, \bar{\psi})$, где $\bar{\theta} \in \{0,1\}^W$ реализует регуляризующее отсечение признаков $\theta_w = \mathbb{I}[\text{Corr}(f(w,t), f(w,t+1)) \geq r]$, а $\bar{\psi}$ — коэффициенты локальных AR-моделей для отобранных слов.

2. Эмпирический прирост качества.

Для синтетического и новостного корпусов предложенный метод уменьшил среднеквадратичную ошибку прогноза $\mathcal{L}$ на 91 %.

$$\Delta \text{MSE} = \frac{\mathcal{L}_{\text{base}} - \mathcal{L}_{\text{corr}}}{\mathcal{L}_{\text{base}}} \times 100\% > 0,$$

где $\mathcal{L}_{\text{base}}$ — значение для классического ARIMA, $\mathcal{L}_{\text{corr}}$ — для предложенного метода.

3. Условия из критерия применимости метода.

Алгоритм целесообразен при выполнении условий

$$\frac{\sigma_{\text{noise}}^2}{\sigma_{\text{core}}^2} \gg 1, \quad \rho_w(1) \approx 0 \quad \text{для } w \in \mathcal{W}_{\text{noise}},$$

то есть когда дисперсия шумовых слов доминирует над variance core-слов, а их лаг-1 автокорреляция пренебрежимо мала. В этом случае фильтрация $\bar{\theta}$ значительно повышает стабильность прогноза $\hat{\bar{v}}(t+1)$.

8 Заключение

В работе предложен метод прогноза вектора долей тем $\bar{\nu}(t) \in \Delta^K$, учитывающий неоднородность корреляционных свойств отдельных слов. В классической авторегрессионной модели ARIMA агрегированная доля $\nu_k(t) = f(T_k, t) / \sum_j f(T_j, t)$ прогнозируется напрямую на основе $\{\nu_k(t-1), \dots, \nu_k(t-t_0)\}$. Такой подход плохо работает при наличии шумовых компонент: white-noise-слов (WN) и spike-decay-слов (SD), чьи автокорреляции $\rho_w \approx 0$ и большие дисперсии искажают $\text{Var } f(T_k, t)$ и снижают лаг-1 корреляцию $\rho_k(1)$ у агрегата.

В отличие от этого, предложен алгоритм:

$$\begin{aligned} \hat{\rho}_w &= \text{Corr}(f(w, t), f(w, t+1)), \quad \theta_w = \mathbb{I}[\hat{\rho}_w \geq r], \\ s(w, t) &= \frac{f(w, t)}{\sum_{v:\theta_v=1} f(v, t)}, \quad \hat{s}(w, t+1) = g_{\psi_w}(s(w, t-1:t-t_0+1)), \\ \tilde{s}(w, t+1) &= \hat{s}(w, t+1) / \sum_{v:\theta_v=1} \hat{s}(v, t+1), \\ \hat{\nu}_k(t+1) &= \sum_{w \in T_k} \theta_w \tilde{s}(w, t+1), \quad \hat{\bar{\nu}}(t+1) \in \Delta^K. \end{aligned}$$

Отбор θ_w удаляет WN/SD-слова, оставляя подмножество core-слов с $\rho_w > r$. Для каждого такого слова строится локальная AR-модель g_{ψ_w} . Агрегация прогнозов по нормированным $\tilde{s}(w, t+1)$ даёт прогноз $\hat{\nu}_k(t+1)$.

На синтетических данных и корпусе новостей показано, что

$$\mathcal{L}_{\text{corr}} = \frac{1}{|T_{\text{test}}|} \sum_{t \in T_{\text{test}}} \|\bar{\nu}(t) - \hat{\bar{\nu}}(t)\|_2^2 \ll \mathcal{L}_{\text{base}},$$

и среднее MSE снизилось более чем на 90%. Это подтверждает гипотезу: $\mathbb{E}[\mathcal{L}_{\text{corr}}] < \mathbb{E}[\mathcal{L}_{\text{base}}]$, где $\mathcal{L}$ — функционал ошибки (??), для синтетического корпуса с шумовыми словами.

Планы дальнейших исследований.

1. Анализ устойчивости порога r : изучение адаптивного отбора $\{r(t)\}$ в зависимости от стационарности ряда.

2. Расширение горизонта $h > 1$: разработка многошагового прогноза $\widehat{v}(t+h)$ с учётом взаимодействия слов между шагами.
3. Многомерные AR-подмодели: совместная оценка $\{s(w_i, t)\}_{i=1}^m$ вместо набора независимых AR-моделей.
4. Интеграция нейронных сетей: использование RNN/Transformer для нелинейного прогнозирования $\{\widetilde{s}(w, t)\}$ после отсева шумовых компонент.

Таким образом, предложенный корреляционный подход демонстрирует высокую точность и интерпретацию прогноза долей тем, что делает его перспективным в задачах мониторинга динамики тематических потоков при высокой волатильности.

Список литературы

- [1] Sentence transformers: all-minilm-l12-v2 t.
- [2] Дас А. Основы вариационного автокодировщика (vae). 2020.
- [3] Джордан М. И. Блей Д. М., Нг Э. Ю. Латентное распределение Дирихле (lda). // Journal of Machine Learning Research. – 2003. – Т. 3. – С. 993–1022.
- [4] Донье Ж. Гоулд М. Бушо Ж.-П., Бонар Ж. Сделки, котировки и цены: Финансовые рынки под микроскопом. // Cambridge University Press, 2018.
- [5] Стрижов В. В. Грабовой А. В. Кластеризация квазипериодических временных рядов для распознавания активности человека. // 2019.
- [6] Гуревих И. Раймерс Н. Sentence-bert: Векторные представления предложений с использованием сиамских bert-сетей. // arXiv preprint arXiv:1908.10084, 2019.
- [7] Абере К. Раппаз Ж., Буржуа Д. Модель динамического встраивания медийного ландшафта. In Материалы конференции The World Wide Web Conference. // 2019. – С. 1544–1554.
- [8] Хиннебург А. Рёдер М., Бот А. Исследование пространства метрик когерентности тем. In Материалы восьмой международной конференции АСМ по веб-поиску и извлечению данных (WSDM). // 2015. – С. 399–408.
- [9] Гарднер Э. С. Экспоненциальное сглаживание: Современное состояние. // Journal of Forecasting. – 1985.
- [10] Холт Ч. С. Прогнозирование сезонности и трендов с помощью экспоненциально взвешенных скользящих средних. // International Journal of Forecasting. – 2004. – Т. 20, № 1. – С. 5–10.
- [11] Янг М.-Ш. Синага К. П. Нераспознаваемый алгоритм кластеризации k-средних. // IEEE Access. – 2020. – Т. 8. – С. 80716–80727.
- [12] Летам Б. Тейлор С. Дж. Прогнозирование в масштабе. // The American Statistician. – 2018. – Т. 72, № 1. – С. 37–45.
- [13] Вариан Х. Чхве Х. Прогнозирование настоящего с помощью google trends. // Economic Record. – 2012. – Т. 88. – С. 2–9.

- [14] Стоффер Д. С. Шамвей Р. Х. Анализ временных рядов и его приложения. // Springer, 2000. – Т. 3.