

Прогнозирование высоковолатильных временных рядов социальных трендов и общественных интересов

Егор Валерьевич Задворнов

Московский физико-технический институт

Специализация: Интеллектуальный анализ данных

Направление: 09.03.01 Информатика и вычислительная техника

Научный руководитель: к.ф.-м.н. А. С. Малков

2025

Цель исследования

Повысить точность прогноза распределений тематик в текстовых документах, распеределённых во времени, с помощью метода, устойчивого к циклическим¹ словам.

Проблема

Классические регрессионные (AR) подходы прогнозирования распределения тематик неустойчивы к появлению нерегулярных циклических слов тематик.

Предлагаемое решение

Предлагается повысить точность AR-моделей с помощью выделения подмножества слов словаря, коррелирующих с временным распределением соответствующих тематик.

¹Под циклом подразумевается изменение с переменным периодом, непривязанное ко времени, которое не портит предположение о слабой стационарности временного ряда. Отражают компоненту цикличности с переменным периодом, увеличивают дисперсию ошибки прогноза.

Обозначения и исходные данные

Обозначения и исходные данные

Рассматривается конечное множество тематик (кластеров)

$\overline{T} = \{T_1, \dots, T_K\}$ и словарь $\mathcal{W}_{\text{all}}$, содержащий $W = |\mathcal{W}_{\text{all}}|$ слов. Каждой тематике T_k соответствует подмножество слов $T_k \subset \mathcal{W}_{\text{all}}$.

Для каждого слова w и момента времени t задана частота:

$f(w, t): \mathcal{W}_{\text{all}} \times \{0, \dots, t-1\} \rightarrow \mathbb{N}_{\geq 0}$

K — число тематик, T_k — тематика, $f(w, t)$ — частота слова w в момент t .

Целевая переменная - распределение тематик во времени

$$\nu_k(t) := \frac{\sum_{w \in T_k} f(w, t)}{\sum_{j=1}^K \sum_{w \in T_j} f(w, t)}, \quad \bar{\nu}(t) := (\nu_1(t), \dots, \nu_K(t)), \quad \sum_{k=1}^K \nu_k(t) = 1$$

Постановка задачи

Вероятностная модель

Последовательность наблюдений $\{\bar{\nu}(t)\}$ рассматривается как реализация случайного процесса, где:

$$\bar{\nu}(t) = \mu_t + \varepsilon_t, \quad \varepsilon_t \sim \mathcal{N}(0, \Sigma_t)$$

Прогнозная модель оценивает условное математическое ожидание:

$$\widehat{\bar{\nu}}(t \mid \bar{\phi}, t-1:t-t_0) = \mathbb{E}[\bar{\nu}(t) \mid \mathcal{F}_{t-t_0:t-1}]$$

где $\mathcal{F}_{t-t_0:t-1}$ - σ -алгебра, порождённая наблюдениями $\{f(w, \tau)\}_{w \in \mathcal{W}, \tau=t-t_0}^{t-1}$.

Задача оптимизации

Минимизация квадратичной ошибки эквивалентна максимизации правдоподобия при нормальном шуме:

$$\min_{\bar{\phi} \in \mathbb{R}^d} \sum_t \left\| \bar{\nu}(t) - \widehat{\bar{\nu}}(t \mid \bar{\phi}, t-1:t-t_0) \right\|_2^2$$

Цель

Построить устойчивую модель прогноза распределения тематик в условиях аномальных значений и циклических изменений.

Построение тематических кластеров из словаря

Постановка задачи кластеризации

$\mathcal{W}_{\text{all}} = \{w_1, \dots, w_W\}$. Найти решение $\bar{T}$, $T_i \cap T_j = \emptyset$, $\bigsqcup_k T_k = \mathcal{W}_{\text{all}}$.

Существующие методы решения

► *Embeddings+K-Means*: $\min_{T_k} \sum_{k=1}^K \sum_{w \in T_k} \|\mathbf{e}_w - \mu_k\|^2$, $\mathbf{e}_w = E(w)$.

► *Latent Dirichlet Allocation(LDA)*:

$$p(\theta, \phi, z, w | \alpha, \beta) = \prod_{k=1}^K p(\phi_k | \beta) \prod_{d=1}^D p(\theta_d | \alpha) \prod_{n=1}^{N_d} p(z_{dn} | \theta_d) p(w_{dn} | \phi_{z_{dn}}).$$

Оптимизация K - числа тематик.

$K^* = \arg \min_K \frac{1}{K} \sum_{m=1}^K C_{\text{cv}}(c_m)$, где C_{cv} — мера когерентности тем.

$C_{\text{cv}} = \frac{1}{|\mathcal{S}_{\text{set}}^{\text{one}}|} \sum_{(W_0, W_*) \in \mathcal{S}_{\text{set}}^{\text{one}}} \tilde{m}_{\cos(\text{nlr}, 1)}(W_0, W_*)$ где

$\mathcal{S}_{\text{set}}^{\text{one}} = \{(\{w_i\}, W) \mid w_i \in W \subset \mathcal{W}_{\text{all}}\}$ и $\tilde{m}_{\cos(\text{nlr}, 1)}$ — косинусное сходство между векторами множеств W_0 и W_* .

Классический подход к прогнозу тематик

Авторегрессионная модель

Для каждой тематики $T_k \in \overline{T}$ используется модель вида:

$$\hat{\nu}_k(t+1) = g_{\psi_k}(\nu_k(t), \dots, \nu_k(t - t_0 + 1))$$

где g_{ψ_k} — модель предсказания тематик, прогнозирующая динамику каждой темы независимо.

Прогноз распределения тематики

Условное математическое ожидание следующего значения распределения при заданной предыстории:

$$\hat{\nu}_k(t+1) := \mathbb{E}_{\hat{\psi}_k}[\nu_k(t+1) \mid \mathcal{F}_t].$$

Функционал ошибки

Среднеквадратичное отклонение прогнозов от фактических значений распределения тем:

$$\mathcal{L} = \sum_t \|\bar{\nu}(t) - \hat{\bar{\nu}}(t)\|_2^2$$

Ограничения подхода в условиях высокой волатильности

Выделяемые подмножества слов исходного словаря и связь с теорией временных рядов

1. $\mathcal{W}_{\text{core}}$ — слова с устойчивой временной структурой и высокой автокорреляцией: тренды (плавные долгосрочные изменения) и сезонные компоненты (периодические колебания с постоянным периодом):

$$\mathcal{W}_{\text{core}} = \{w \in \mathcal{W}_{\text{all}} \mid \rho_w := \text{Corr}(f(w, t), f(T_k, t + 1)) \geq r, \text{ где } w \in T_k\}$$

2. $\mathcal{W}_{\text{WN}}$ — мультитематические слова: моделируются случайной ошибкой из-за высокой вероятности перехода между тематиками:

$$\mathcal{W}_{\text{WN}} = \{w \in \mathcal{W}_{\text{all}} \mid f(w, t) = [\varepsilon_w(t)]_+, \rho_w = 0\}$$

3. $\mathcal{W}_{\text{SD}}$ — циклы: изменения с переменным периодом. Сохраняют стационарность, но увеличивает дисперсию ошибки прогноза:

$$\mathcal{W}_{\text{SD}} = \{w \in \mathcal{W}_{\text{all}} \mid f(w, t) = [S_w(t) + \varepsilon_w(t)]_+, \rho_w(\tau) \approx 0\},$$

$$S_w(t) = \sum A_{w,m} \kappa(t - \tau_{w,m}), \kappa(\tau) = \frac{e^{-\lambda|\tau|}}{1 + \tau^2}$$

Влияние шумовых слов на прогноз тематик

Утверждение 1 (Задворнов, 2025)

Пусть $\mathcal{W}_{\text{all}} = \mathcal{W}_{\text{core}} \cup \mathcal{W}_{\text{WN}} \cup \mathcal{W}_{\text{SD}}$, $\mathcal{W}_a \cap \mathcal{W}_b = \emptyset$ при условии попарной некоррелированности компонент

$$\forall a \neq b, \forall \tau \in \mathbb{Z}: \quad \text{Cov}(f^{(a)}(T_k, t), f^{(b)}(T_k, t + \tau)) = 0$$

Тогда

$$\text{Cov}(f(T_k, t), f(T_k, t + 1)) = \text{Cov}(f^{(\text{core})}(t), f^{(\text{core})}(t+1))$$

и

$$\rho_k(1) = \frac{\text{Cov}^{\text{core}}}{\text{Var}^{\text{core}} + \sigma_{\text{WN}}^2 + \sigma_{\text{SD}}^2}.$$

Вывод

1. В условиях высокой волатильности $\mathcal{W}_{\text{WN}} \cup \mathcal{W}_{\text{SD}}$ понижают автокорреляцию $\rho_k(1)$, нарушая предпосылки AR-моделей о существенной корреляционной зависимости, и уменьшают точность прогноза.
2. Необходим подход, устойчивый к $\mathcal{W}_{\text{WN}} \cup \mathcal{W}_{\text{SD}}$.

Предлагается алгоритм ARFilter

Принцип работы

1. Формируется вектор корреляций между частотами слов и будущими значениями соответствующих тематик.
2. Выделяется набор слов $\mathcal{W}_{\text{core}}$ с устойчивой временной структурой.
3. Для каждого выделенного слова строится отдельная AR-модель, прогнозирующая относительные доли:

$$s(w, t) = \frac{f(w, t)}{\sum_{v \in \mathcal{W}_{\text{core}}} f(v, t)}$$

4. Прогноз относительной доли тематики вычисляется как сумма прогнозов слов, входящих в неё.

Теоретическое обоснование эффективности

Теорема (Задворнов, 2025)

Пусть для тематики T_k :

1. $\mu_k = \mathbb{E}[\nu_k(t) \mid \mathcal{F}_{t-1}]$ - условное матожидание распределения по всем словам
2. $\mu_k^{(\text{core})} = \mathbb{E}[\hat{\nu}_k^{(\text{core})}(t) \mid \mathcal{F}_{t-1}]$ - условное матожидание по core-словам
3. Выполнены условия Утверждения 1 о разбиении словаря

и дополнительно выполнены условия на шумовые слова:

1. Для $w \in \mathcal{W}_{\text{WN}}$: $\mathbb{E}[f(w, t) \mid \mathcal{F}_{t-1}] \leq C_{\text{WN}}\sigma_{\text{WN}}$
2. Для $w \in \mathcal{W}_{\text{SD}}$: $\mathbb{E}[f(w, t) \mid \mathcal{F}_{t-1}] \leq C_{\text{SD}}\sigma_{\text{SD}}$ (в отсутствие пиков)
3. $|\mathcal{W}_{\text{WN}}|C_{\text{WN}}^2 + |\mathcal{W}_{\text{SD}}|C_{\text{SD}}^2 < \kappa$

где $\kappa > 0$ - минимальное собственное значение информационной матрицы модели прогноза.

Тогда:

$$\mathbb{E}[\mathcal{L}_{\text{ARFilter}} \mid \mathcal{F}_t] := \text{MSE}(\hat{\nu}_k^{(\text{core})}(t)) < \text{MSE}(\hat{\nu}_k^{(\text{all})}(t)) =: \mathbb{E}[\mathcal{L}_{\text{baseline}} \mid \mathcal{F}_t]$$

Псевдокод алгоритма ARFilter

Algorithm ARFilter

Require: Корпус $\mathcal{D} = \{(d_i, t_i)\}_{i=1}^N$, порог r , окно t_0

Ensure: $\overline{T}$, $\overline{\theta}$, $\overline{\psi}$

- 1: Извлечь $\mathcal{W}_{\text{all}}$ и частоты $f(w, t)$ по $\mathcal{D}$
 - 2: $\overline{T} = \{T_k\}$ с помощью вероятностной модели
 - 3: **for all** $w \in \mathcal{W}_{\text{all}}$ **do**
 - 4: $\hat{\rho}_w \leftarrow \text{Corr}(f(w, t), f(T_k, t + 1))$, где $w \in T_k$
 - 5: $\Theta_w \leftarrow \mathbb{I}[\hat{\rho}_w \geq r]$
 - 6: **end for**
 - 7: $\mathcal{W}_{\text{core}} \leftarrow \{w : \Theta_w = 1\}$
 - 8: **for all** $w \in \mathcal{W}_{\text{core}}$ **do**
 - 9: $s(w, t) \leftarrow \frac{f(w, t)}{\sum_{v \in \mathcal{W}_{\text{core}}} f(v, t)}$
 - 10: $\psi_w \leftarrow \arg \min_{\psi} \sum_{t \in \mathcal{T}_{\text{train}}} (s(w, t) - g_{\psi}(s(w, t - 1 : t - t_0)))^2$
 - 11: **end for**
 - 12: **return** $\overline{T}$, $\overline{\theta}$, $\overline{\psi}$
-

Цель вычислительного эксперимента

Основная гипотеза

На синтетических данных $\mathbb{E}[\mathcal{L}_{\text{ARFilter}} \mid \mathcal{F}_t] < \mathbb{E}[\mathcal{L}_{\text{baseline}} \mid \mathcal{F}_t]$.

Генератор данных

1. 3 кластера: Sports, Music, Tech
2. В каждом: 4 core-слова, 8 white-noise, 8 spike-decay
3. Ключевые слова Core: тренд + сезонность + шум
 $\sigma_{\text{core}} = 0.4$
4. Случайные слова по распределению WN: $\mathcal{N}(5, 36)$
5. Циклические слова SD вида гиперболический всплеск с экспоненциальным затуханием

Условия эксперимента

1. Временной ряд состоит из 40 точек (80 недель)
2. Разделение на обучающую и отложенную выборку: 39/1
3. Базовый метод: ARIMA с выбором порядка по AIC
4. Метрики: MSE по всем кластерам

Результаты вычислительного эксперимента

Сравнение по кластерам ($\times 10^{-3}$ MSE $\pm$ SE)

Метод	Sports	Music	Tech	Avg
Классический (baseline)	41.0 $\pm$ 0.9	13.0 $\pm$ 0.8	16.0 $\pm$ 0.1	23.0 $\pm$ 1.3
Предложенный	1.0 $\pm$ 0.0	3.0 $\pm$ 0.2	3.0 $\pm$ 0.2	2.0 $\pm$ 0.1

Основные выводы

1. MSE классического подхода: $(23.0 \pm 1.3) \times 10^{-3}$
2. MSE предложенного: $(2.0 \pm 0.1) \times 10^{-3}$
3. Ранжированный порядок тем сохраняется при реализации погрешности, что подтверждает устойчивость результатов
4. Подтверждение $\mathbb{E}[\mathcal{L}_{\text{ARFilter}} \mid \mathcal{F}_t] < \mathbb{E}[\mathcal{L}_{\text{baseline}} \mid \mathcal{F}_t]$.

Результаты вычислительного эксперимента

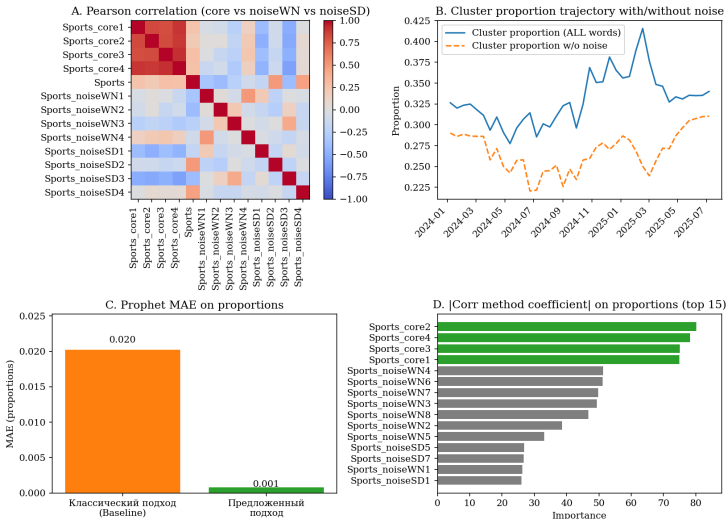


Рис.: Визуализация проверки гипотезы. Четыре панели иллюстрируют статистические свойства синтетического кластера *Sports*

Результаты вычислительного эксперимента

Анализ результатов

- A. Матрица корреляций $\rho(f(w, t), f(u, t))$: блок core–core показывает высокую корреляцию с тематикой, WN/SD-блоки близки к нулю.
Следствие: Подтверждается необходимость подхода, устойчивого к $\mathcal{W}_{WN} \cup \mathcal{W}_{SD}$.
- B. Траектория $\nu_{\text{Sports}}(t)$ для всех слов vs только core-слов.
Следствие: Шумовые слова увеличивают дисперсию прогноза.
- C. MAE: $|T_{\text{test}}|^{-1} \sum_{t \in T_{\text{test}}} |\hat{\nu}(t) - \nu(t)|$ снижается в 20 раз.
Следствие: Алгоритм ARFilter превосходит классический подход.
- D. Корреляционные коэффициенты $|\beta_w|$: core-слова доминируют (зеленый), шумовые близки к нулю (серый).
Следствие: Корреляционный алгоритм эффективно выделяет информативные признаки.

Выносятся на защиту

1. Метод прогнозирования тематик во времени с использованием регуляризации при условии высокой волатильности

1.1 Регуляризация через отбор признаков:

$$\theta_w = \mathbb{I}[\text{Corr}(f(w, t), f(T_k, t + 1)) \geq r], \text{ где } w \in T_k$$

1.2 Локальные модели прогноза для отобранных признаков

2. Эмпирическое подтверждение эффективности

На синтетических данных достигнуто снижение MSE на 91%:

$$\Delta \text{MSE} = \frac{\mathcal{L}_{\text{base}} - \mathcal{L}_{\text{corr}}}{\mathcal{L}_{\text{base}}} \times 100\%$$

3. Условия из критерия применимости метода

Метод эффективен при условиях:

$$\frac{\sigma_{\text{noise}}^2}{\sigma_{\text{core}}^2} \gg 1, \quad \rho_w(1) \approx 0 \text{ для } w \in \mathcal{W}_{\text{WN}} \cup \mathcal{W}_{\text{SD}}$$

Список литературы



Choi, H., Varian, H. (2012)

Predicting the Present with Google Trends

Economic Record, 88, 2–9



Rappaz, J., Bourgeois, D., Aberer, K. (2019)

A Dynamic Embedding Model of the Media Landscape

The World Wide Web Conference, 1544–1554



Taylor, S. J., Letham, B. (2018)

Forecasting at Scale

The American Statistician, 72(1), 37–45



Shumway, R. H., Stoffer, D. S. (2000)

Time Series Analysis and its Applications

Springer



Gardner, E. S. (1985)

Exponential Smoothing: The State of the Art

Journal of Forecasting